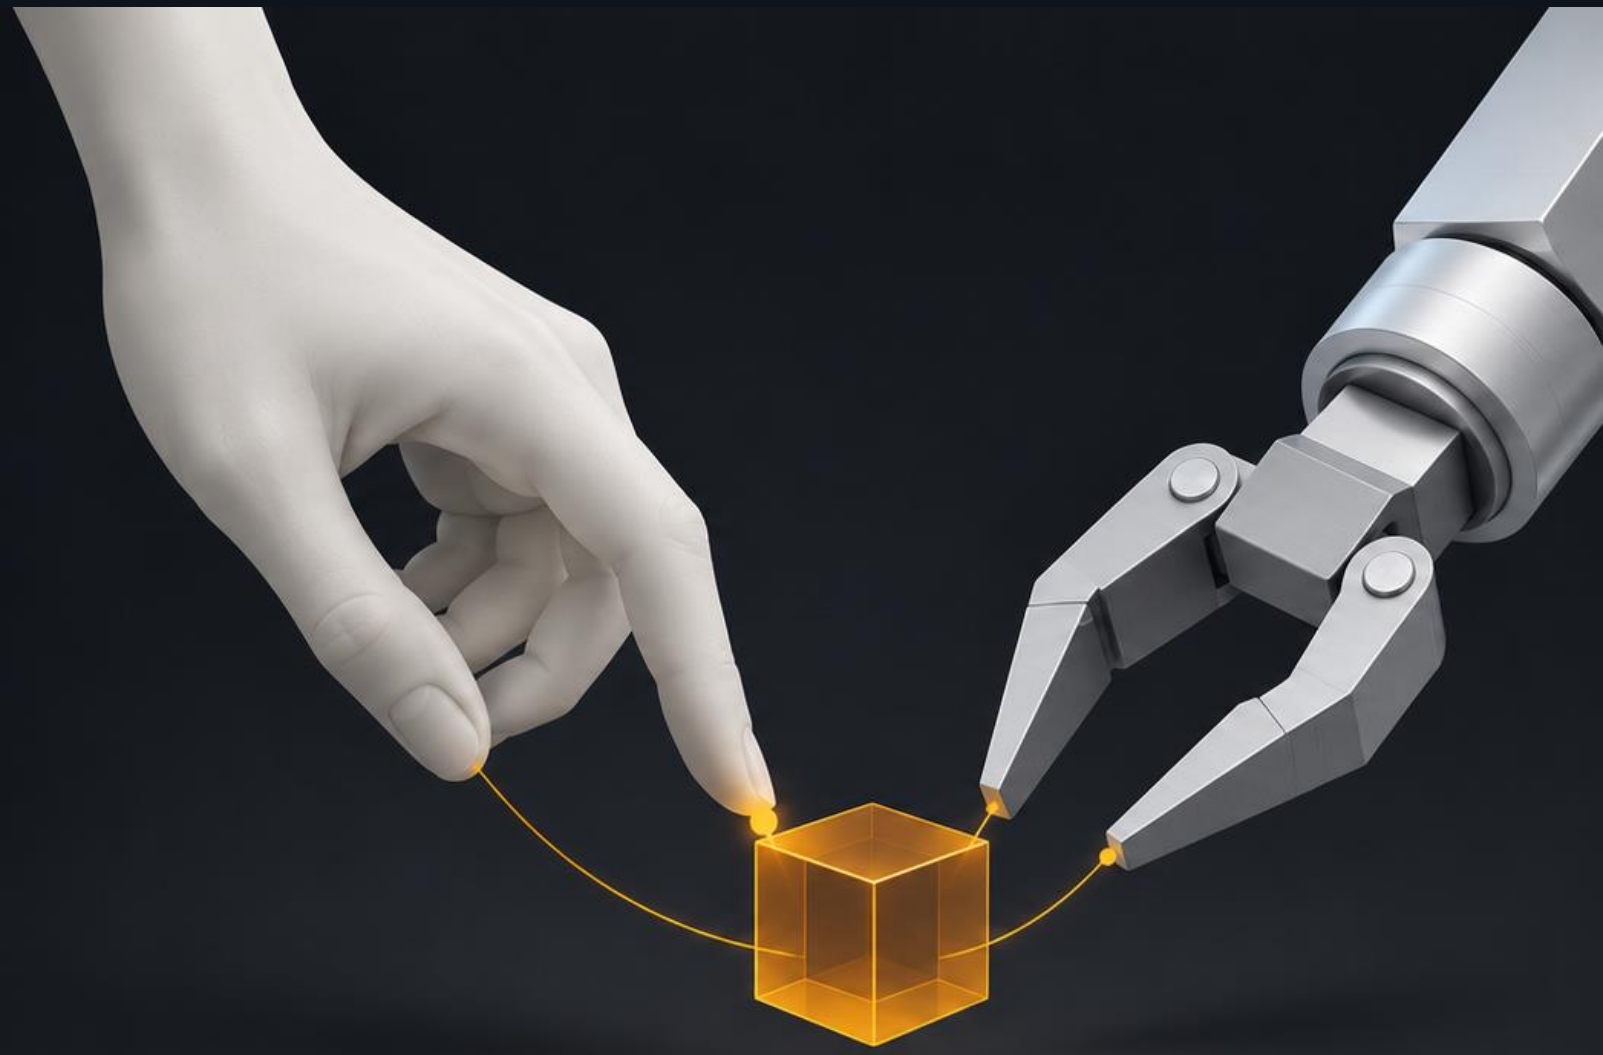
物理智能的多模态基础



陈凯 / 深度机智

北京中关村学院 / 中关村人工智能研究院 · 2026.11

物理智能技术路径收敛：大模型

OpenAI、Google DeepMind 与 Anthropic 的公开路径

公司	代表进展	与具身智能的关系
OpenAI	GPT-6 Astra / GPT-Live 1 GPT-6.1 Terra（2026.09–10）	视觉、推理、语音与工具基础
Google	Gemini Robotics 2（2026.07） Argon for Robotics（2026.10）	**高**层具身推理与低层动作协同 扩展到全身操作、仿真与控制
Anthropic	Claude plays robotics（2026.07） MHS **研究**预览（ 2026.08）	**代理通**过代码和标准接口连接硬件 **底**层策略与闭环反馈仍然关键

共同研究问题：模型如何获得可靠的物理观测，并把推理转化为行动

具身智能没有迎来
GPT 时刻。

GPT 迎来了
具身智能时刻。

通用大模型的能力正在进入物理世界。

人的多元智能结构

加德纳多元智能理论中的八类智能

语言智能

理解与表达

逻辑数学智能

推理与计算

音乐智能

节奏与声音模式

自我认知智能

自我认识与目标

多元智能

在真实任务中协同

空间智能

位置与空间关系

身体运动智能

通过身体行动解决问题

人际智能

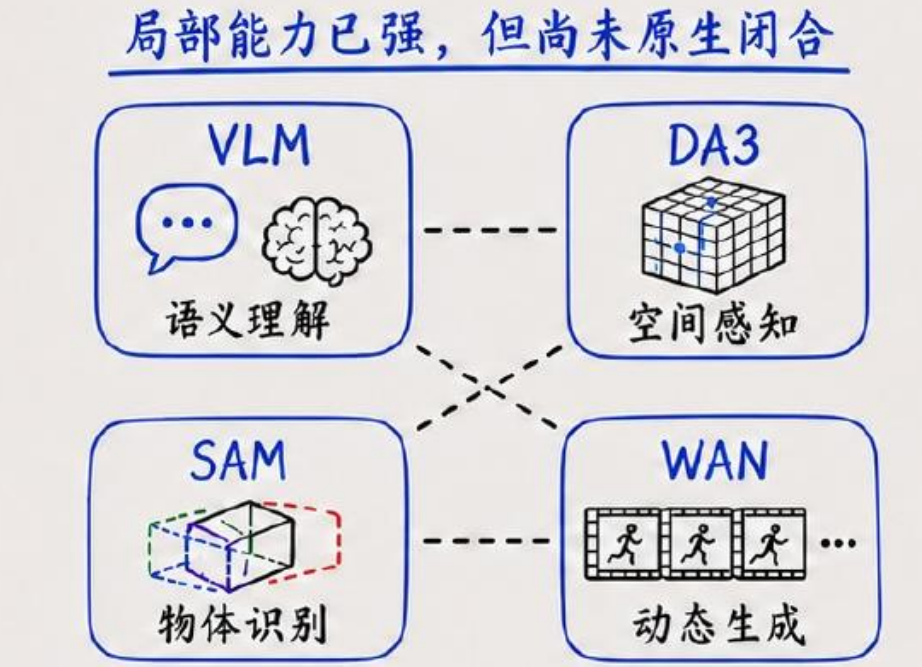
理解他人的意图

自然观察智能

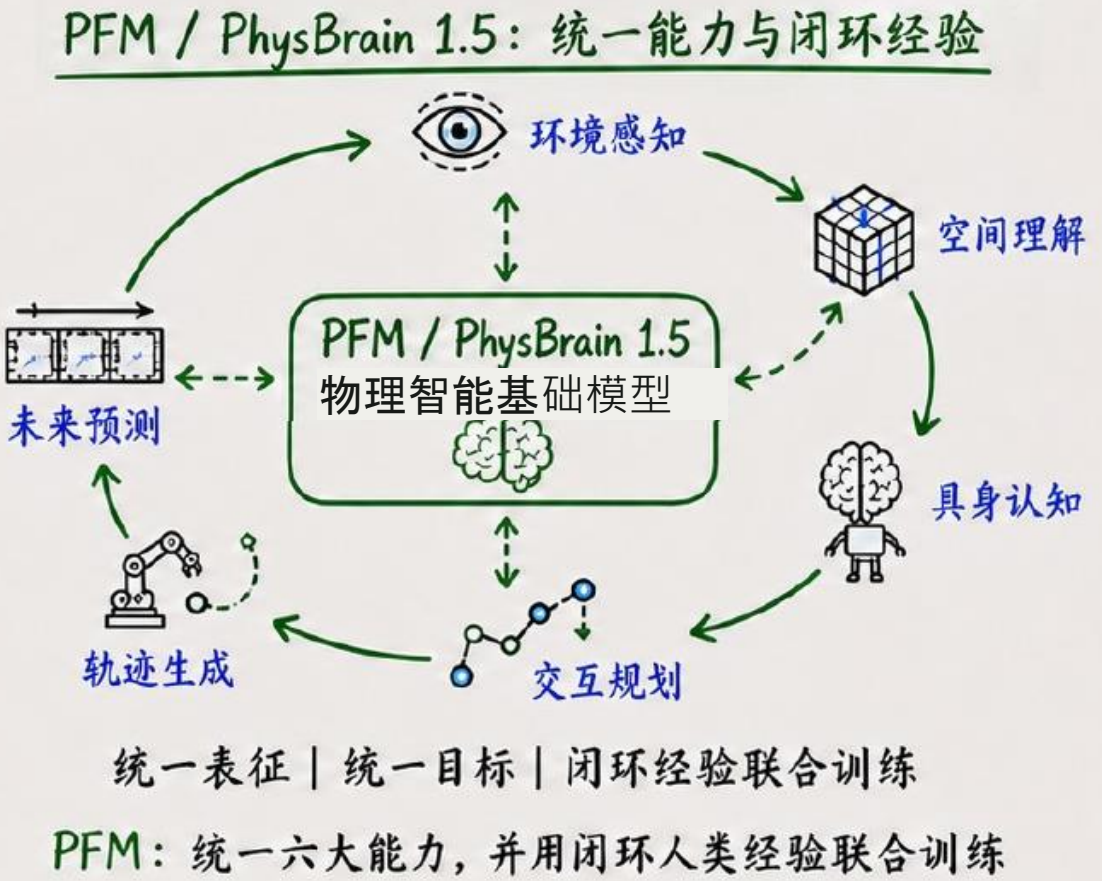
辨识自然界的模式

真实行动依赖多种能力的协同。

基础模型要围绕物理闭环补齐缺失能力



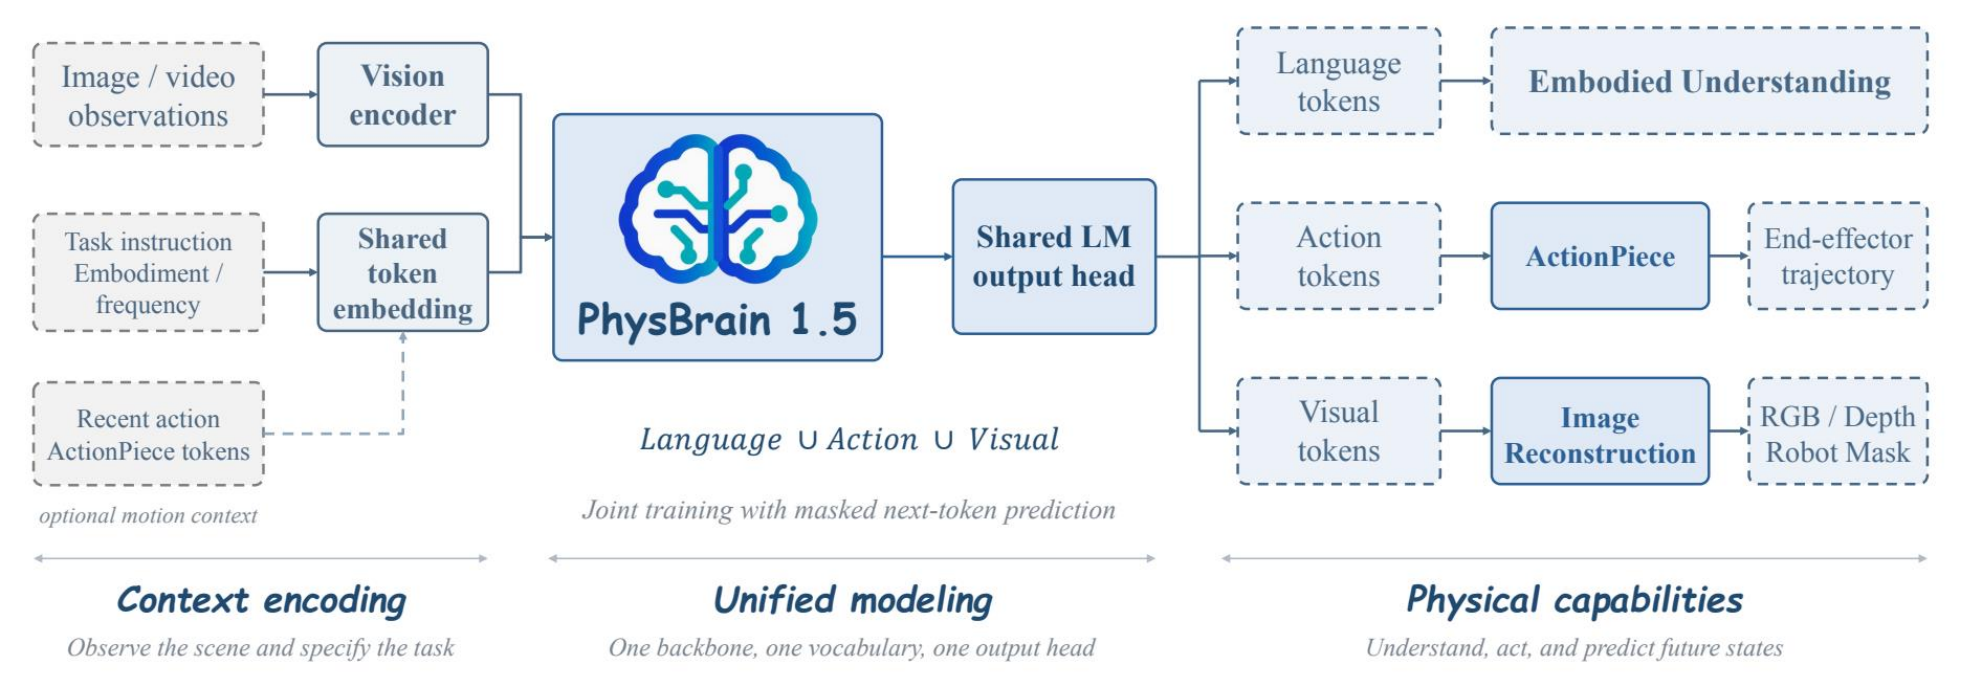
简单拼接仍无法形成物理闭环



物理智能本质上是一个持续修正的闭环

PhysBrain 1.5：统一理解、动作与未来状态

一个自回归骨干，同一词表与输出头



理解观察　　**生成末端动作**　　**预测视觉后果**

DeepCybo Team, PhysBrain 1.5, 2026, Fig. 2。公开模型：2B / 8B。

PhysBrain 1.5 开源版：能力评测

所列开源模型中第一　　14项最优结果　　综合均分72.5

视觉感知

2项基准

空间与多视角

9项基准

具身推理

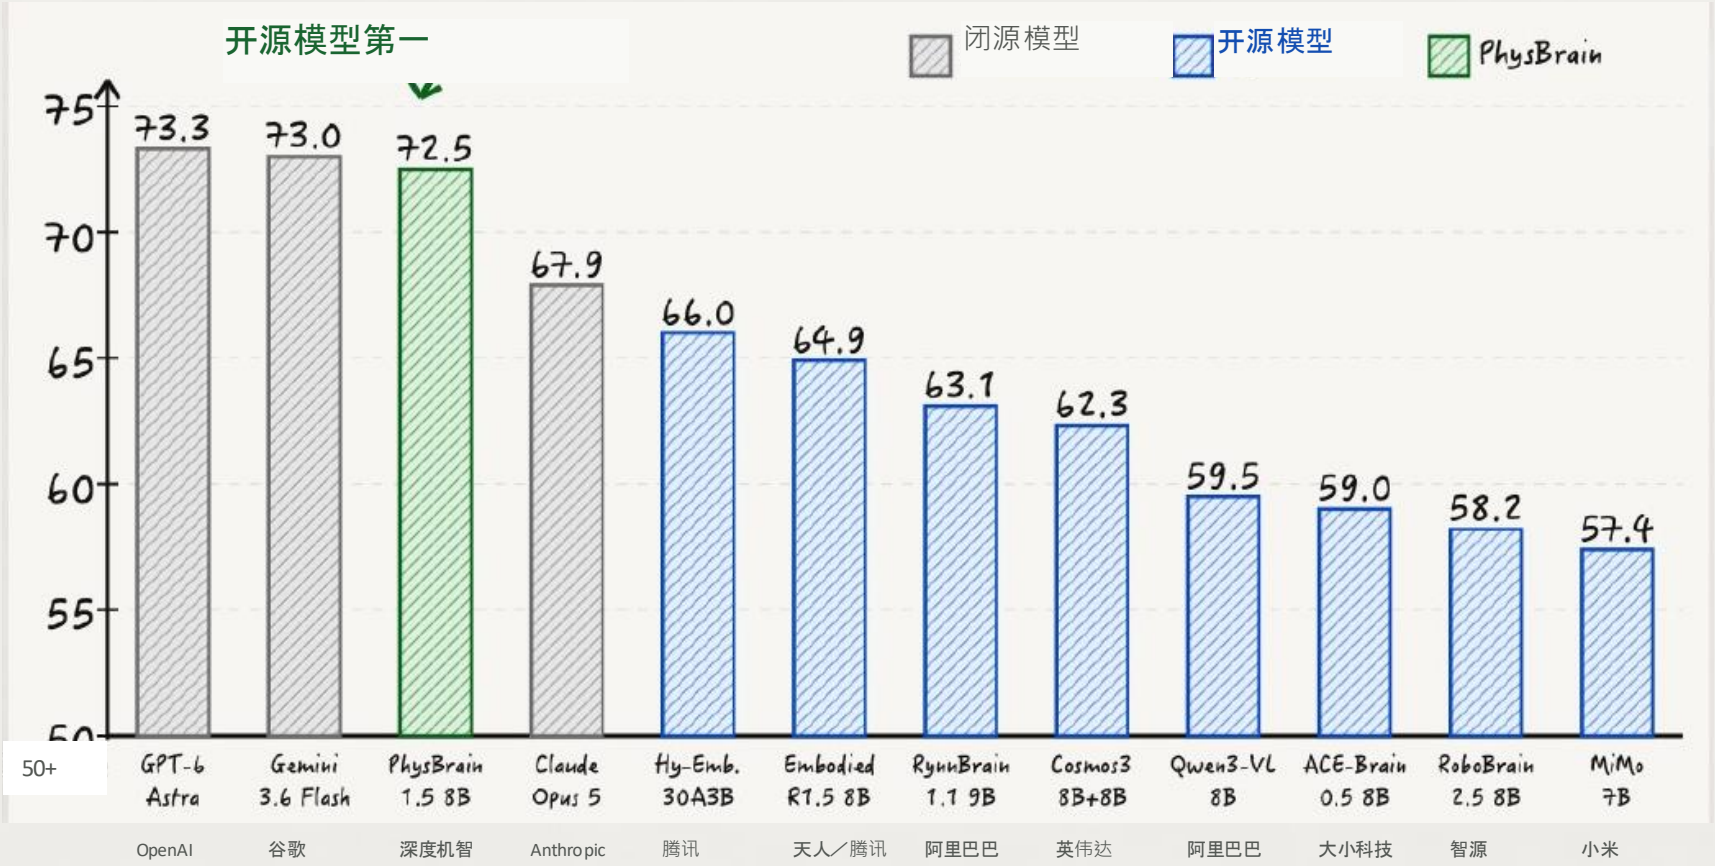
6项基准

空间定位与可供性

9项基准

视觉轨迹

2项基准



来源：团队报告的28项基准平均分；结论限于图中所列模型与评测设置。

场景感知与三维空间理解

场景感知

物体计数与相对深度

BLINK



有几个蓝色泳圈？

答案：1个

CV-Bench



哪个物体
距离相机更近？

答案：桌子

三维空间理解

距离估计与视角关系

Q-Spatial-Bench



研磨机与石块
之间的最短距离？

答案：27厘米

ViewSpatial



台面位于
冰箱的哪一侧？

答案：右侧

动作推理与空间定位

推理与规划

预测下一步动作，识别交互对象

下一步动作预测

接下来最可能发生什么？



答案：将笔放在桌上

交互对象识别



交互对象？
A 书　B 易拉罐
C 盒子　D 杯子
答案：B

定位与指向

定位交互点与目标位置

PointBench：心形花朵

在每朵心形花上标注一个点。



[320,310]
[450,330]
[610,380]
[750,410]

VABench-Point：橙色锅具

将其放在勺子与面包之间。



目标位置：
[410,650]

从有序路径点到连续动作轨迹

理解任务目标，生成有序路径点



伸手抓取勺子

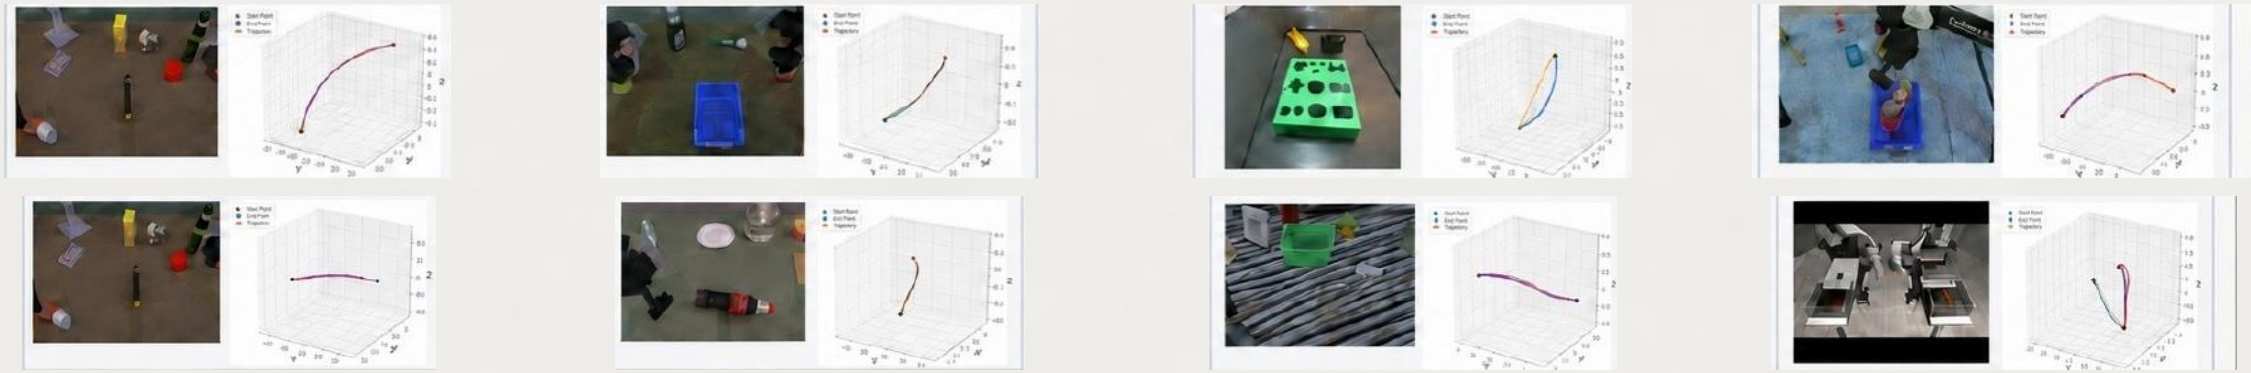
[152, 105] [220, 170]
[280, 240] [340, 320]



将绿色物体
放入碗中

[489, 602] [489, 570] [470, 530] [450, 500]
[435, 530] [435, 570] [435, 610] [435, 635]

轨迹理解 → 轨迹生成



跨场景、跨控制频率的连续轨迹：5赫兹、10赫兹、20赫兹

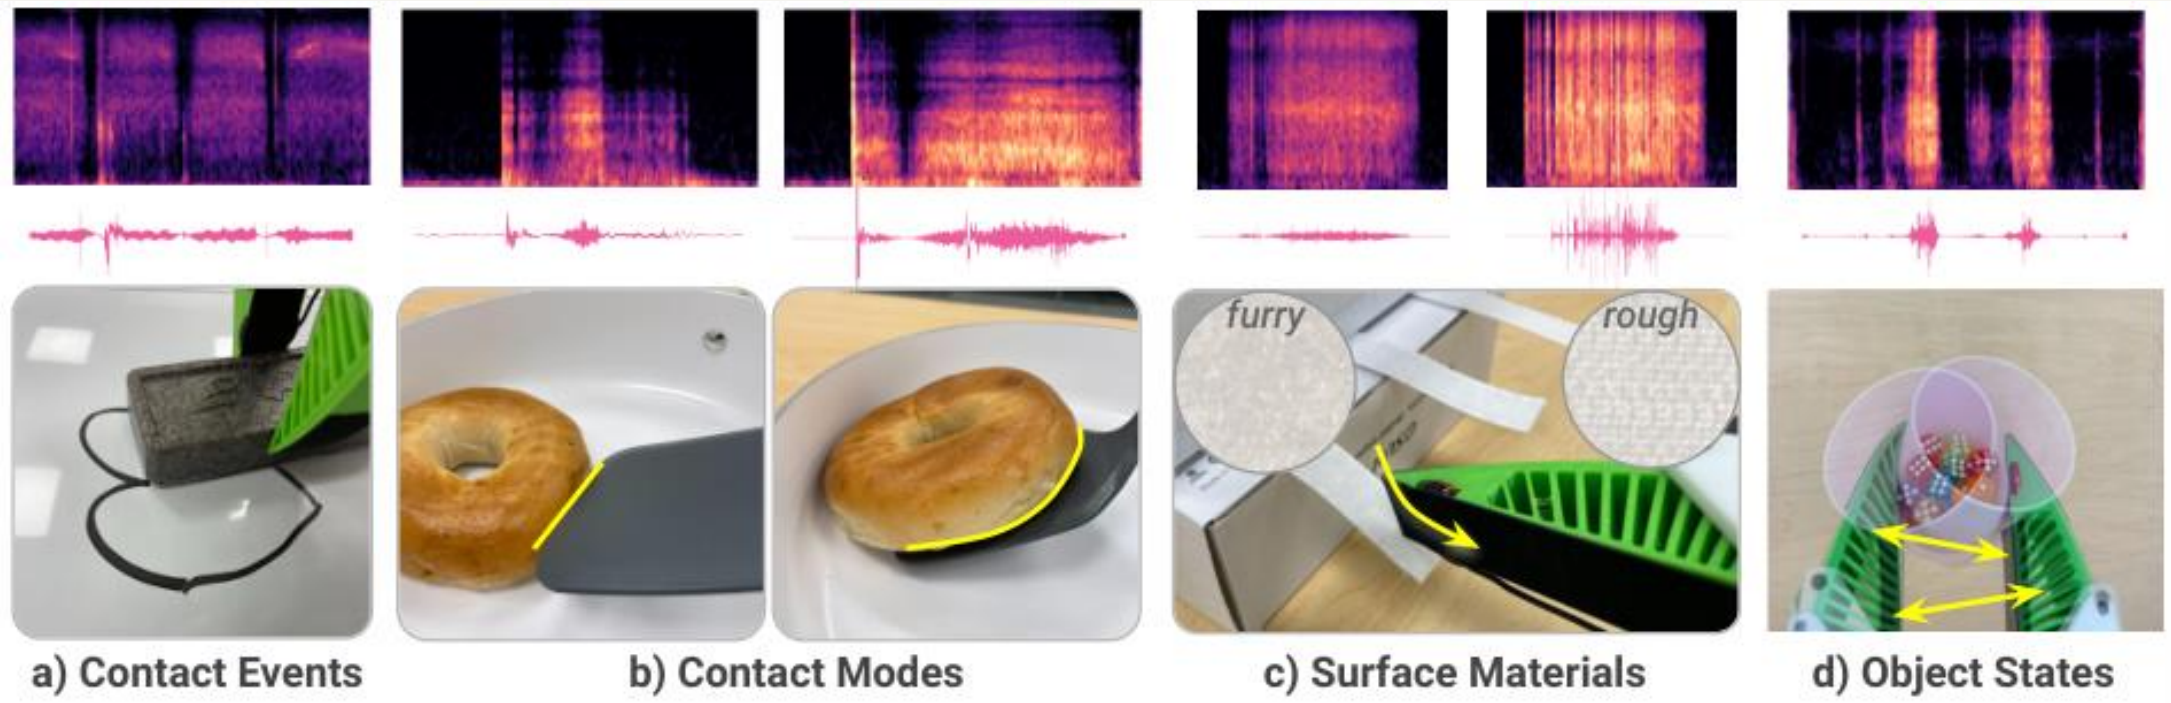
PhysBrain 驱动的60自由度长程灵巧移液



Prime **灵巧机器人，60自由度；演示**视频为双倍速、全程自主操作。

听觉的独特价值：视觉缺失的物理证据

遮挡、内部状态、短暂接触与视野外事件，可以通过声音获得额外观测

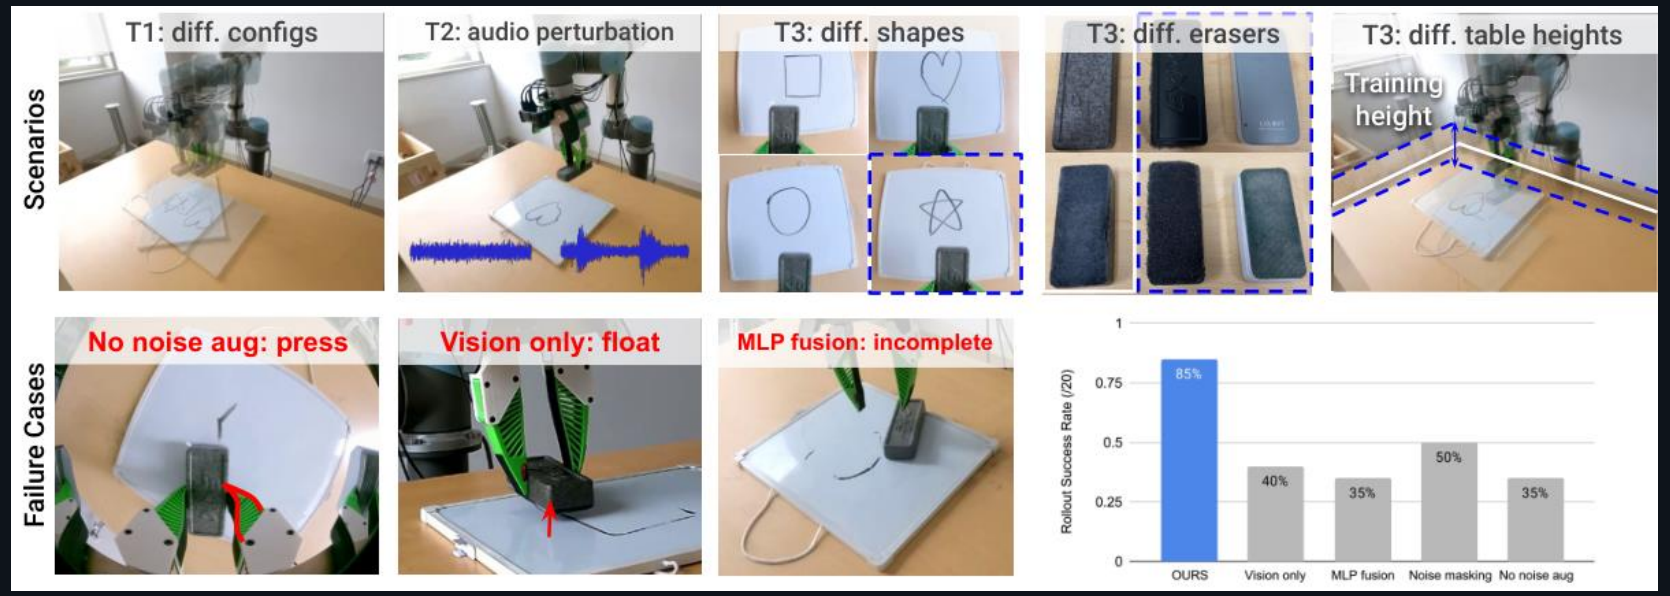


外观相同、内部状态不同时，声音可提供当前画面无法替代的证据

ManiWAV, CoRL 2024, Fig. 1；SoundAct, 2026。**声音种**类与采集位置影响可获得的信息。

接触声音提升操作状态的可观测性

ManiWAV 白板擦拭实验



40% → 85%

视觉　　视听

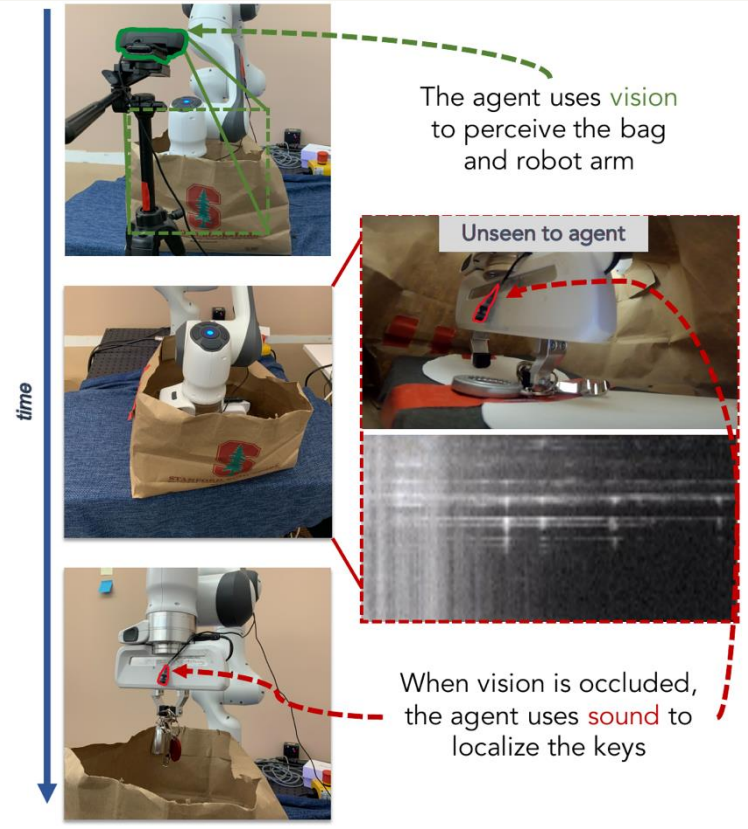
接触状态
成为可用的策略反馈

传感器位置决定证据质量：接触声与环境声需要分别研究

Liu et al., ManiWAV, CoRL 2024, §4.2 / Fig. 6。每策略 20 次测试，使用接触麦克风。

遮挡与视野外：声音引导主动感知

交互声音与空间声源帮助选择下一次观察与行动



遮挡后的内部状态

袋内目标不可见时，交互声音与历史**帮助判断**钥匙位置和探索结果

视野外的空间事件

双耳线索引导末端与腕部相机搜索视觉随后完成目标确认与精细操作

Du et al., Play it by Ear, RSS 2022；Kim & Joo, SoundAct, ICRA 2026 Workshop。

物理听觉的三个研究问题

从声音类别识别，走向可用于行动的物理状态估计

信息在哪里　　环境声提供事件与方向线索，接触声提供局部交互状态

信息由何产生　　区分动作造成的声学反馈、任务叙述与无关背景声音

信息如何迁移　　跨人类与机器人、设备与房间，保持声音和物理状态的对应

声音增益需要任务与干预实验验证

任务类型	要检验的信息	关键测量与干预
遮挡容器与接触	内部是否有物、是否接触或滑动	状态辨识、任务成功率 静音与替换背景音
视野外声源	事件发生位置与时间	定位误差、搜索时间 单声道 / 双耳对照
动作结果判断	操作完成、异常与失败	失败发现与恢复时延 音画错位与语音移除
跨域泛化	房间、材料、设备与自噪变化	跨场景成功率与置信区间 严格隔离训练与测试域

Ego360：先保留，再选择

采集原生全景经验，再按任务派生学习视角



DeepCybo & Insta360, Ego360 研究稿, Fig. 1。全景记录仍需后续构造结构化监督。

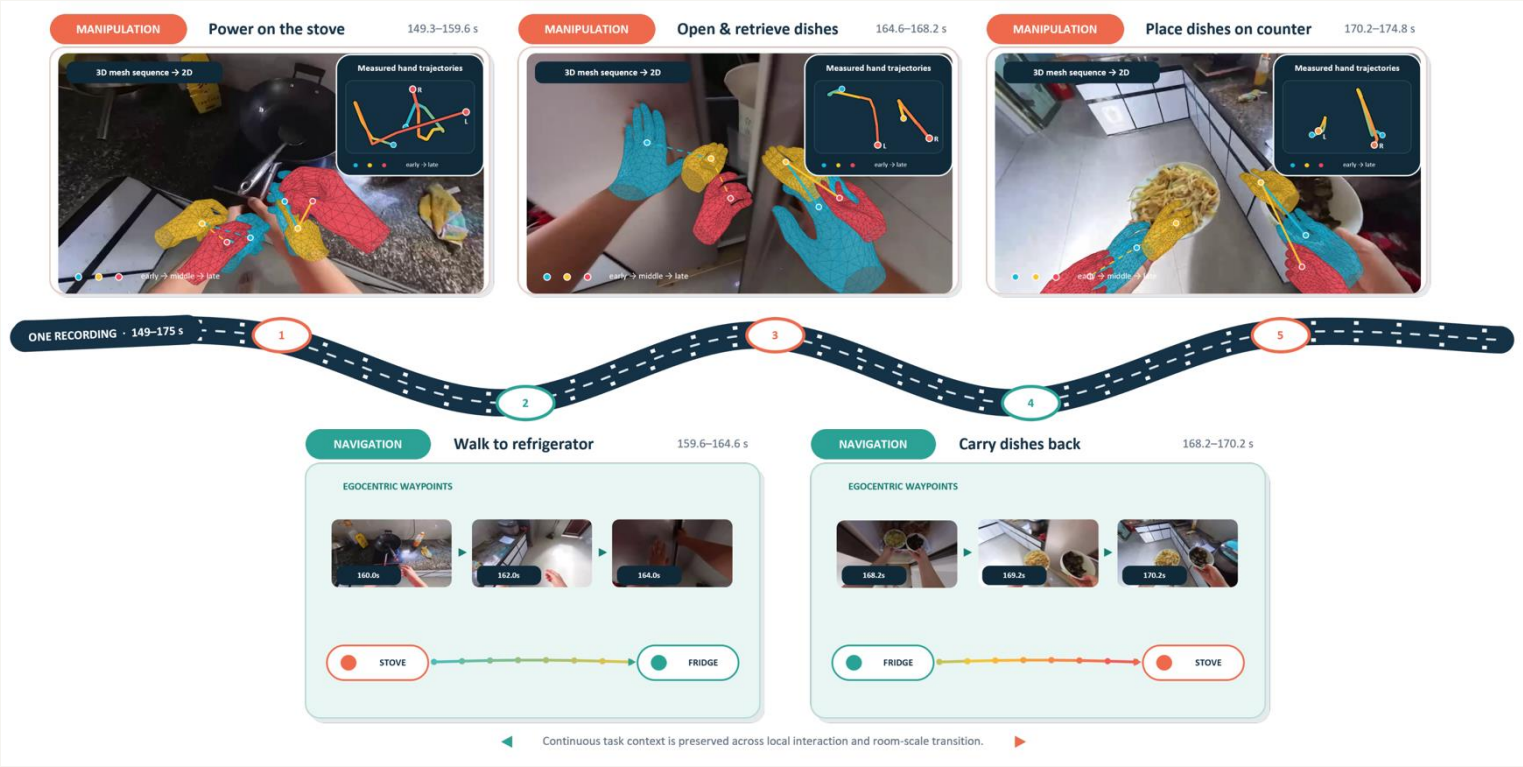
单台颈挂全景记录环境与身体

双鱼眼 360° 视频与同步音频，减少采集时的视角取舍



完整经验包含操作、搜索与移动

连续烹饪任务中的多站点交互



同一段经验连接任务意图、场景变化、人体动作与后续结果

Ego360 的听觉扩展研究

在现有同步音视频基础上，构建面向物理声音的监督

层面	现有基础	拟联合研究
采集	**全景**视频与同步音频 **自然作**业及任务叙述	**原始音**轨保留与时钟审计 **按任**务增加接触 / **空**间声学传感
监督	VAD / ASR / 词级时间对齐 **音画**语义核验	**声源、物理事件、**动作与结果关联 语音和非语音线索分别标注
模型	PhysBrain 1.5 **理解、**动作 **与未来**视觉状态联合学习	**音**频表示与融合机制 **状**态估计和主动感知策略
验证	**既有理解基准与离**线预测	视听消融、抗噪与跨域评测 实机任务成功与失败恢复

合作倡议：共建可验证的多模态物理智能

一个共同任务

一套匹配的采集与对照实验

一项可复现、可共享的研究结果

让模型同时理解看见的世界，
以及声音揭示的物理状态

参考资料：前沿模型与 PhysBrain

OpenAI	GPT-6 Astra / GPT-Live 1 / GPT-6.1 Terra，官方模型文档与更新日志
Google DeepMind	Gemini Robotics 2（2026.07.30）与 Argon for Robotics（2026.10.13）
Anthropic	Claude plays robotics（2026.07.09）与 MHS research preview（2026.08.27）
DeepCybo Team	PhysBrain 1.5: From Vision-Language Models to Physical Foundation Models arXiv:2609.14973，2026.09.14