空间音频合成研究

赵洲

浙江大学

2026年11月

从‘生成声音’到‘生成有位置的声音’

- 通用音频生成：关注“是什么声音”。
- 空间音频生成：进一步关注“声音从哪里来、离多远、如何移动”。

通用音频生成



“声音像不像狗叫”

空间音频生成



方向变化、距离变化和空间感。

从单声道到空间音频表示

➢ 从单声道到空间音频，变化的不只是信号数量，更是表达声音**位置、距离和运动**的能力。

单声道（Mono）



一个声音信号

立体声（Stereo）



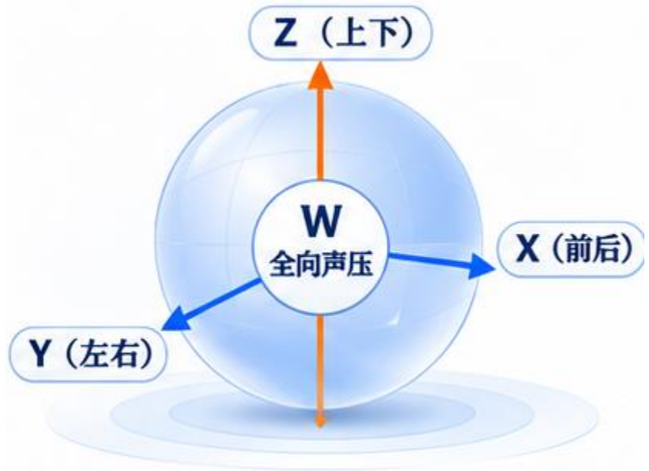
左右两个声音信号

双耳空间音频（Binaural）



两个声音信号方向和远近

一阶 Ambisonics（FOA）

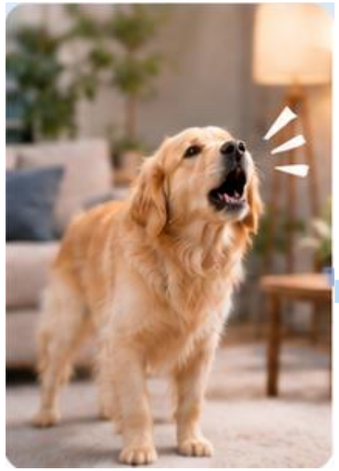


四个分量共同编码声场

联合生成路线

➢ 核心：空间音频生成要同时保证**声音内容**和**空间表达**；用于沉浸式交互时，还要**及时响应。**

① 输入场景或内容描述



例如：一只狗在房间里叫。

② 输入空间信息



指定听者朝向、声源起点与终点，以及运动轨迹。

③ 模型联合生成



同时理解声音内容和空间信息。

④ 输出空间音频



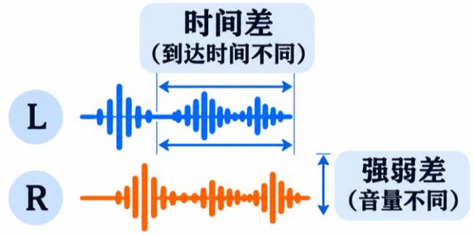
带有方向和空间变化的音频。

➢ 声音内容和空间变化要同步



位置声音变化匹配

➢ 保持正确的空间关系



时间差、强弱差

➢ 面向交互应用，还需兼顾低延迟



及时响应

空间音频数据准备

➢ 将**空间音频**与内容描述、空间条件等信息按任务配对，形成可用于**模型训练**的数据。

真实空间录音



- 在真实场景中采集空间音频。
- 如双耳麦克风、Ambisonics麦克风。

模拟生成数据



- 用HRTF、房间声学等方法将普通音频空间化。
- 设置声源位置、距离与运动轨迹。

声源位置 方向、距离
运动轨迹 如从后到前
听者信息 朝向、头部
场景/环境 房间、混响

实录：同步追踪声源与听者的位置和朝向。

仿真：直接保存设定的位置、轨迹和房间参数。

音频 →

空间信息 →
起点：后方，2.0 m
终点：左前方，1.0 m
运动：直线，持续3 s
环境：室内，中等混响



评测基准

➢ **结合客观指标与主观听评，评价声音质量、内容匹配和空间表达。**

① 客观评测：用指标检查生成结果

□ 声音质量与内容匹配



- FAD↓：生成与真实音频的特征分布是否接近。
- CLAP↑：声音内容与文本描述是否匹配。

□ 方向与声场分布



- 双通道：ITD误差↓，比较两耳到达时间差。
- FOA：能量图CC/AUC↑，比较声场分布。

□ 运动与时变声场



- FSAD↓：比较动态空间特征的分布，也可按时间窗比较声场，检查空间变化。

② 主观听评

□ 让听者实际判断



- 自然度：声音是否自然？
- 符合度：内容是否匹配？
- 空间感：位置和运动是否符合设定？

空间音频合成路线

➢ 声音内容正确，方向、距离和运动符合设定。

● 路线一：先有声音，再空间化（分步合成）

声音素材



录制或先生成
一段普通声音。

空间化模块

结合位置、轨迹和房间信息，
为已有声音补上空间效果。

● 路线二：声音与空间一起生成（联合生成）

内容描述＋空间条件



文本、视频、位置等

联合生成模型

同时学习“声音是什么”
和“声音在哪里”，
直接生成空间音频。

共同输出



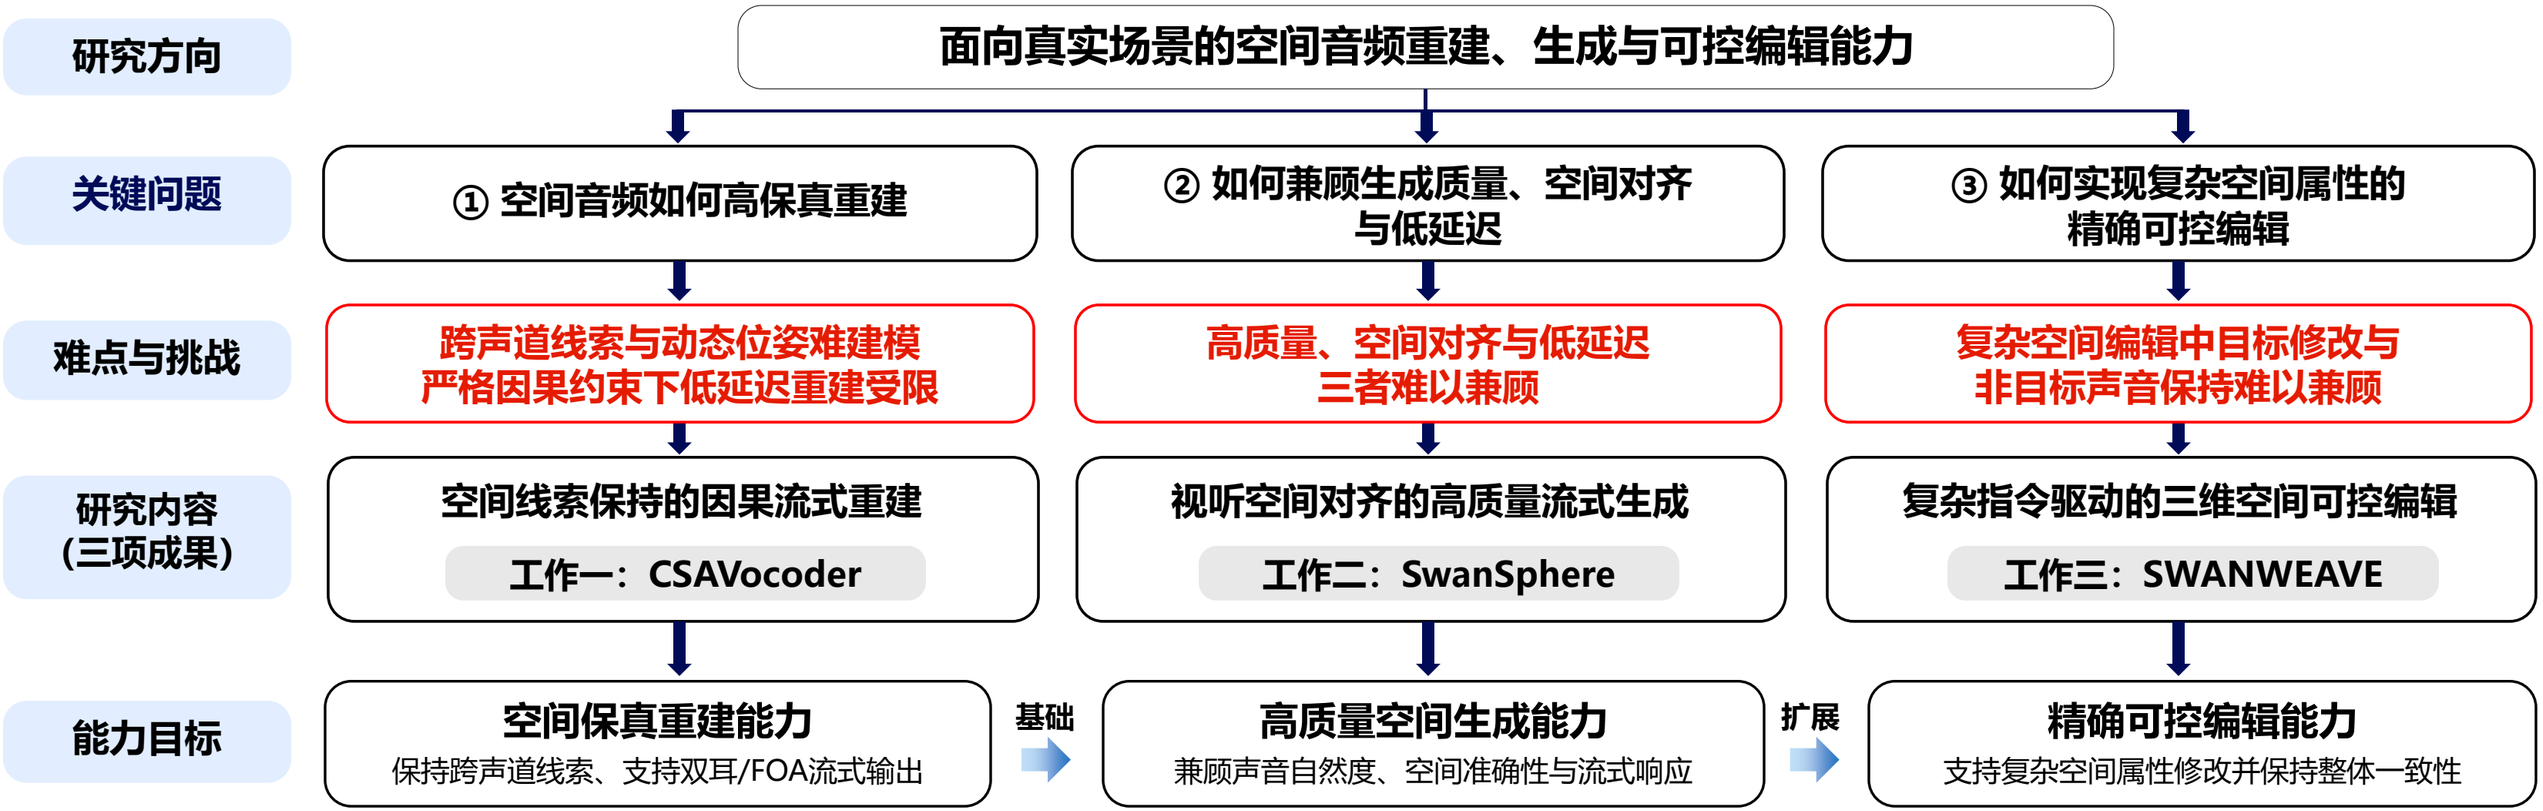
双耳音频、FOA等

双耳音频可用耳机播放，
FOA需按播放设备解码。

研究目标·研究内容

项目目标

面向沉浸式交互，实现空间音频从“声音清晰、空间可感”向“**声场真实、视听一致、精准可控**”的提升。



技术突破

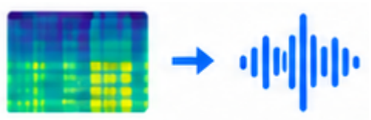
突破**跨声道空间线索保持的因果流式重建**、**视听空间对齐的高质量低延迟生成**、**复杂指令驱动的三维空间音频可控编辑**等关键技术。

挑战一：严格因果重建下的空间线索保持难题

➢ **核心挑战：如何在严格因果和低延迟约束下，将多声道声学特征重建为高质量波形，同时保持正确的跨声道空间线索？**

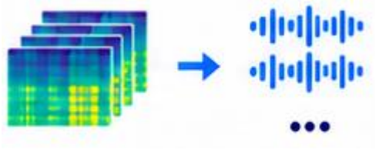
现有方法及不足

通用神经声码器



不足：主要面向单声道或普通立体声，跨声道关系建模不足。

空间扩展声码器



不足：直接扩展易忽略通道间的空间一致性，空间质量下降。

流式语音声码器



不足：主要针对语音等单声道场景，难以满足空间音频的高保真重建需求。

本项目思路（CSAVocoder）

➢ **多模态特征融合**

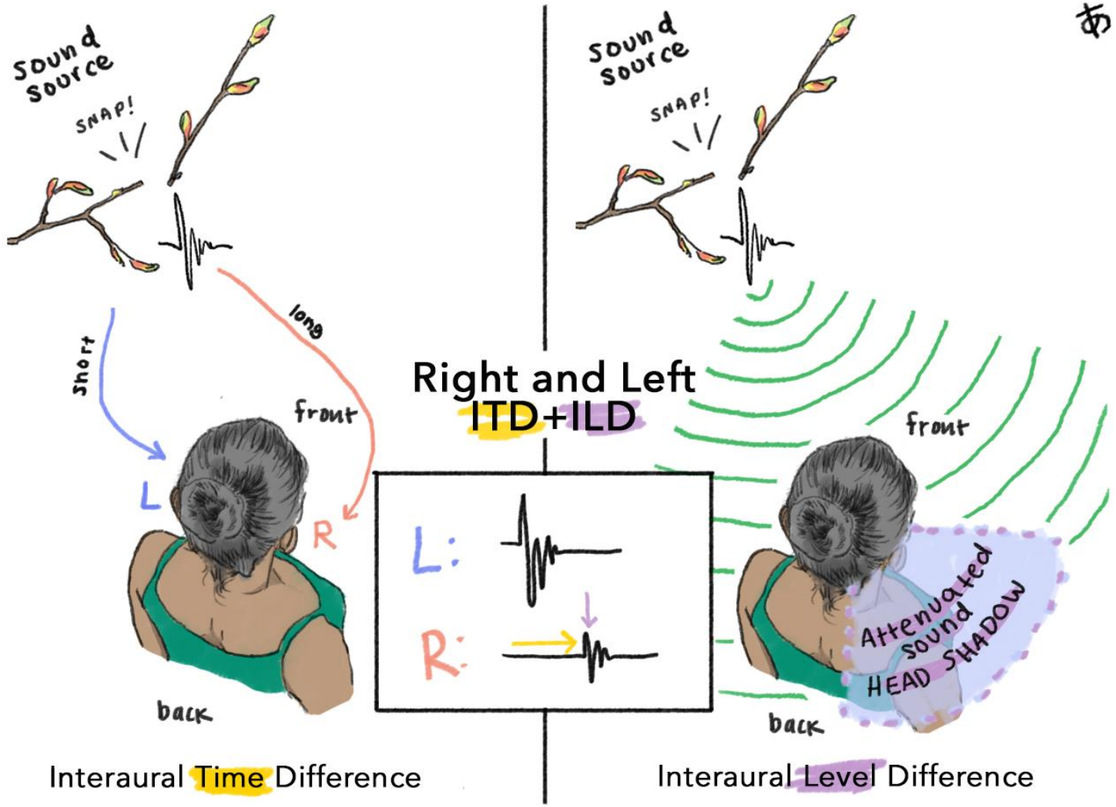
➢ **空间一致性监督**

➢ **严格因果与状态缓存**

CSAVocoder：严格因果重建下的空间线索保持

➢ **在严格因果条件下，还原清晰声音并保持正确的跨声道空间关系。**

● **双耳定位线索示意**



● **任务**

- 输入多声道 Mel 频谱和相对位姿，逐块输出双耳或 FOA 空间音频波形。

● **空间线索**

- 各声道不仅要清晰，还需保持正确的强弱、相位及相关关系，才能还原空间感。

● **流式约束**

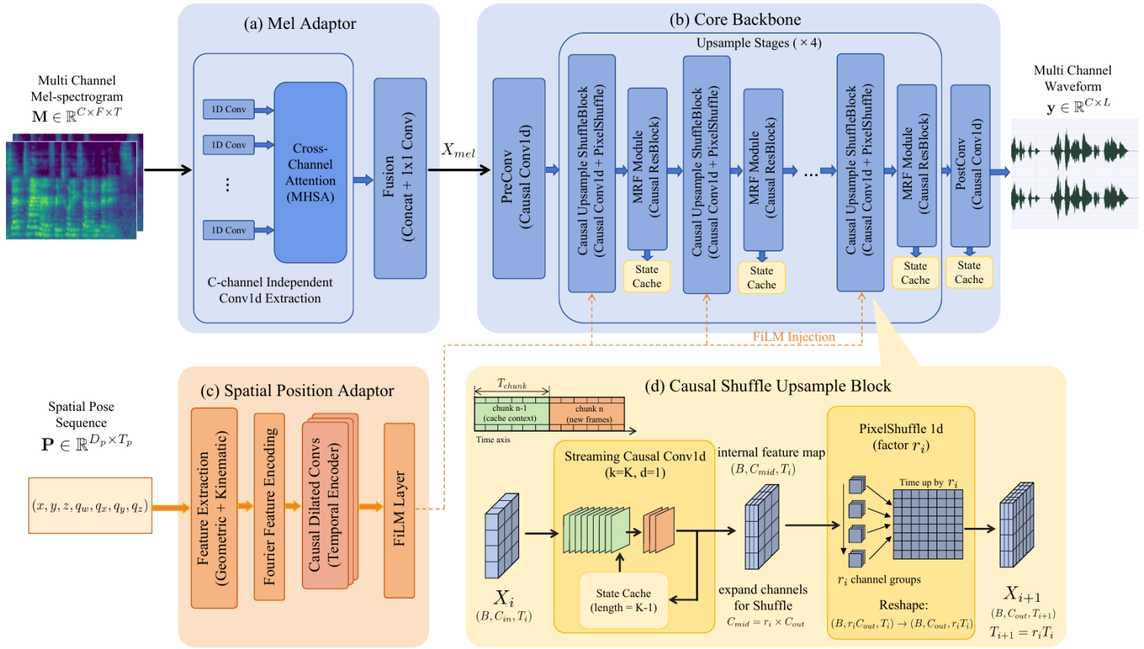
- 当前输出只依赖当前与历史输入，分块衔接时还要保持声音与空间变化连续。

https://github.com/MM-Speech/CSAVocoder

创新一：空间适配器融合多声道频谱与动态位姿

➢ **核心：跨声道频谱与动态位姿联合适配，为因果生成器提供空间条件。**

空间条件化的声码器



- **Mel Adaptor：学习跨声道关联**

  - 先逐声道提取频谱特征，再用跨声道注意力建模关联，形成生成器的声学输入。

- **位姿适配器**

  - 对 7 维相对位姿加入运动差分和傅里叶编码，以因果时序建模捕捉动态变化。

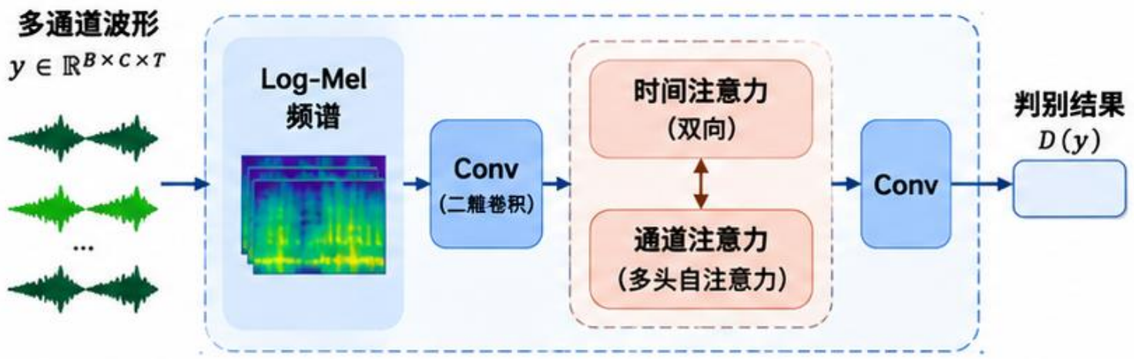
- **FiLM：将空间条件注入生成器**

  - 位姿特征产生缩放与偏置，在上采样模块中调制声学特征，联合指导空间波形重建。

创新二：空间一致性判别与格式感知的空间损失

➢ **核心：用空间判别监督和格式感知损失，显式约束多声道之间的空间关系。**

空间一致性判别器（SCD）



双耳：相位差与声级差约束

$$L_{spatial} = \lambda_{IPD} L_{IPD} + \lambda_{ILD} L_{ILD}$$

FOA：方向、声强、扩散度与能量约束

$$L_{spatial} = \lambda_{iv} L_{iv,dir} + \lambda_{r} L_{r} + \lambda_{diff} L_{diff} + \lambda_{elog} L_{elog}$$

- **SCD：用判别监督学习空间关系**

  - 训练时通过时间与声道双轴注意力输出评分，参与对抗学习，显式约束跨声道一致性。

- **双耳约束**

  - 相位差约束侧重低频定位线索，声级差约束侧重高频强弱差异。

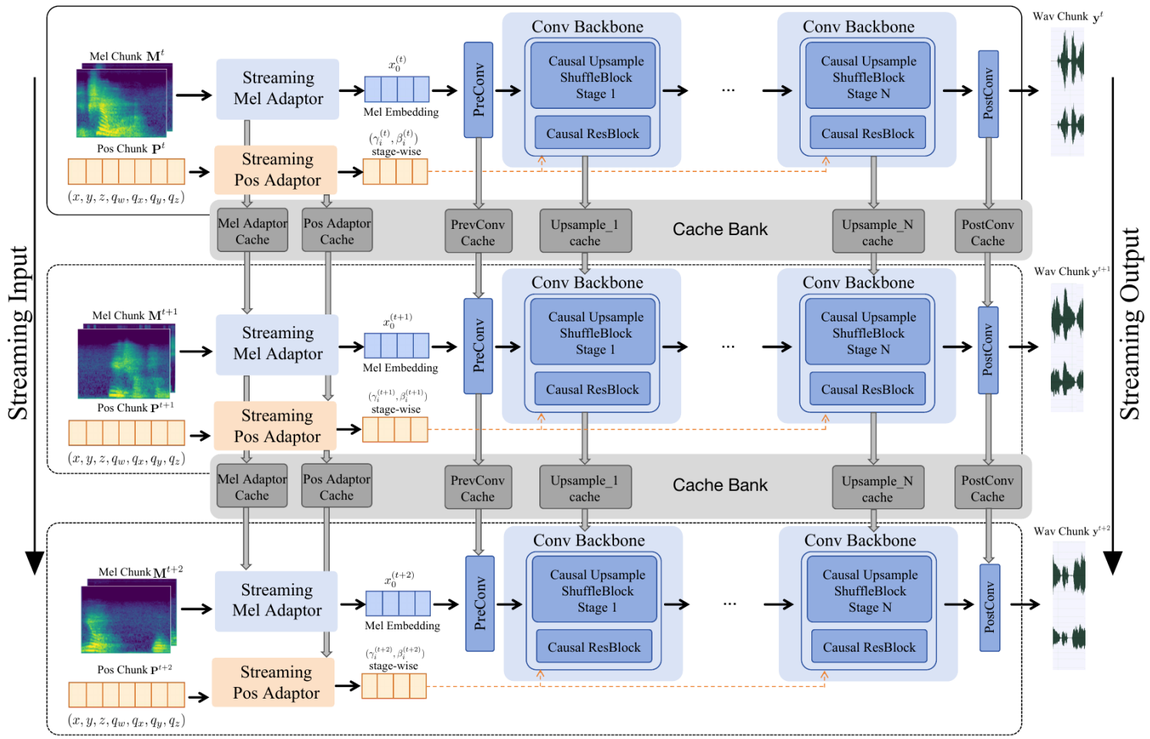
- **FOA 约束：保持声场方向与扩散**

  - 联合声强方向、归一化声强、扩散度与对数能量四项损失，保持声场空间关系。

创新三：严格因果与状态缓存支持连续流式合成

➢ **核心：严格因果运算与分层缓存协同，在不读取未来输入的条件下连续合成。**

分块推理与状态缓存



当前块 + 历史缓存 → 当前波形块 + 更新缓存

- **严格因果**
  - 因果卷积只用当前与历史输入；零前视仍有输入分块和计算等待。
- **通道重排**
  - 先用因果卷积扩展特征通道，再通过 PixelShuffle 完成时间维度上采样。
- **状态缓存**
  - 各层保留所需历史状态，下一块直接复用并更新，避免重复计算并支持长时生成。

数据集构建与评测体系

➢ **结合双耳与 FOA 数据，从音质、空间保持与实时能力评估声码器。**

室内场景示意



客厅



卧室



走廊

双耳音频

600 h，约 35 万条样本

FOA 音频

900 h，约 31 万条样本

- **数据构建：结合录音与房间仿真**
  - 覆盖静态位置与动态轨迹，含700 段测试，其余按 9 : 1 划分训练与验证。
- **客观评测：音质、空间与实时性**
  - 分别评估音质和空间一致性，同时报告 RTF 与分块推理延迟，检查实时计算能力。
- **主观听评：兼顾质量与空间感**
  - 29 名听众开展 MOS 听评，9 名专家开展 MUSHRA 式评测，评价音质与空间感知。

基线比较：双耳声码器比较与空间一致性评估

➢ 双耳空间一致性更好且满足实时计算要求，音质与 FOA 各指标仍有取舍。

双耳声码器比较

Model	ANG COS (↑)	DIS COS (↑)	MRSTFT (↓)	PESQ (↑)	MCD (↓)	Periodicity(↓)	RTF (↓)
HiFi-GAN	39.07	68.37	1.470	1.562	5.329	0.169	0.0622
CARGAN	30.00	63.71	1.194	1.739	3.377	0.160	0.1348
FARGAN	23.53	56.03	1.219	1.885	3.447	0.161	0.1916
DiffWave	27.05	61.07	1.585	2.070	6.440	0.156	0.1621
PriorGrad	37.18	64.71	1.981	2.364	3.671	0.128	0.1629
FastDiff	29.46	59.93	2.889	2.051	6.948	0.130	0.1174
WaveFM	41.36	71.96	1.079	2.400	2.727	0.141	0.1634
Vocos	40.04	70.23	**1.039**	**2.510**	**1.892**	0.113	**0.0339**
Ours	**62.11**	**77.05**	1.223	2.109	2.153	**0.107**	0.1587

空间化管线

Method	ANG COS (↑)	DIS COS (↑)
GT + DSP	26.65	51.07
Vocos + DSP	23.65	50.02
GT + BinauralGrad	50.83	72.13
Vocos + BinauralGrad	46.45	69.59
ISDrama + HiFi-GAN	45.77	67.70
ISDrama + Ours	47.73	71.44
GT + Ours	**62.11**	**77.05**

- **双耳方向与距离表征更一致**
  - ANG COS 与 DIS COS 均为最高，相同 ISDrama 上游下替换声码器，空间指标也得到改善。
- **质量与格式方面在空间优势**
  - GT+Ours用真实双耳Mel在空间化管线表现最优。
- **效率上计算可跟上音频播放**
  - 单张 RTX 4090 上 RTF = 0.1587 < 1，具备实时计算能力。

消融实验：模块消融与因果约束分析

➢ **跨声道建模、位姿条件与空间监督各有贡献，因果约束使模型支持流式输出。**

适配器与判别器消融

Setting	ANG COS (↑)	DIS COS (↑)
w/o Mel Adaptor	42.60	65.39
Mel Adaptor 2 head	61.03	76.55
Mel Adaptor 8 head	61.50	76.70
w/o SCD	58.82	74.63
w/o Position Adaptor	54.78	70.63
Mel Adaptor 4 head	**62.11**	**77.05**

因果与非因果对照

Model	ANG COS	DIS COS	MRSTFT	PESQ
Vocos	40.04	70.23	**1.039**	**2.510**
Causal Vocos	41.06	71.35	1.240	2.240
Non-causal CSAVocoder	60.21	74.29	1.083	2.397
Causal CSAVocoder	**62.11**	**77.05**	1.223	2.109

- **Mel Adaptor贡献最大**
  - 移除 Mel Adaptor 后空间指标下降最大，使用4个注意力头在论文对照中表现最好。
- **条件和监督互补**
  - 移除位姿适配器或 SCD 都会降低空间指标，说明显式运动条件与空间判别监督各有明显的贡献。
- **因果约束**
  - 同因果性下空间指标仍优于 Vocos，严格因果取消未来信息，多数部分音质指标优于非因果版本。

音频示例

	Ground Truth	CSAVocoder (Ours)	HiFi-GAN	CAR-GAN
示例1				

	FAR-GAN	WaveFM	Vocos
			

	Ground Truth	CSAVocoder (Ours)	HiFi-GAN	CAR-GAN
示例2				

	FAR-GAN	WaveFM	Vocos
			

挑战二：高质量、空间对齐与低延迟流式生成难以兼顾

➢ **核心挑战：如何同时实现高质量的声音生成、视听空间对齐与低延迟的流式输出？**

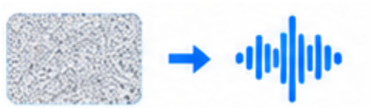
现有方法及不足

自回归生成



不足：采用离散表示，存在量化损失，影响声音质量。

扩散生成



不足：需多步去噪，首块响应延迟高，难以实时生成。

多模态生成



不足：对空间关系建模不足，生成结果易与画面不一致。

本项目思路（SwanSphere）

➢ **分层流式生成**

➢ **视听空间对齐**

➢ **多目标偏好优化**

SwanSphere：流式同步空间音频生成

➢ **通过多模态特征融合、空间一致性监督与严格因果的流式生成，实现高保真、空间一致且低延迟的空间音频波形重建。**



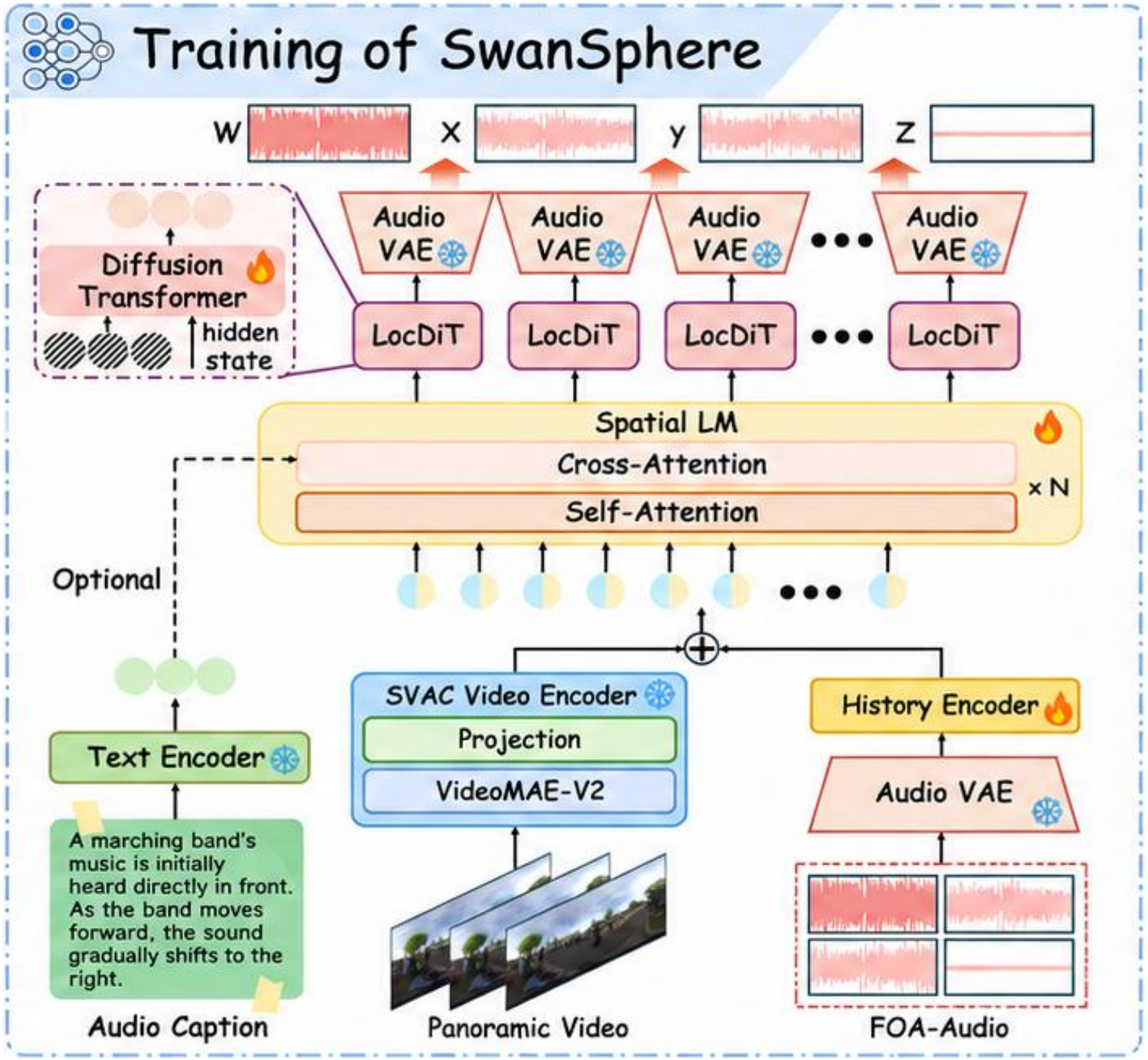
乐队从前方移向右侧,声源在画面中移动，声音方向也随时间变化

- **任务：生成同步的空间音频**
  - 支持视频、文本或联合输入，逐块输出与场景内容、时序及方位一致的四通道 FOA 音频。
- **空间对齐**
  - 不仅要生成对应声音，还要让声音方向随画面中的声源移动而变化。
- **流式响应**
  - 尽快输出首块音频，并兼顾声音质量、空间对齐，保持后续音频块连续。

https://github.com/MM-Speech/SwanSphere

创新一：自回归扩散协同的流式空间音频生成

➢ **核心：自回归建模块间关系，局部扩散生成块内细节，兼顾质量与流式响应。**



- **Spatial LM：建模块间上下文**

  - 结合视频、文本与历史音频，为当前音频块预测生成条件。

- **LocDiT：生成块内声学细节**

  - 在 Spatial LM 条件下，通过流匹配生成连续音频潜变量，再由 FOA-VAE 解码。

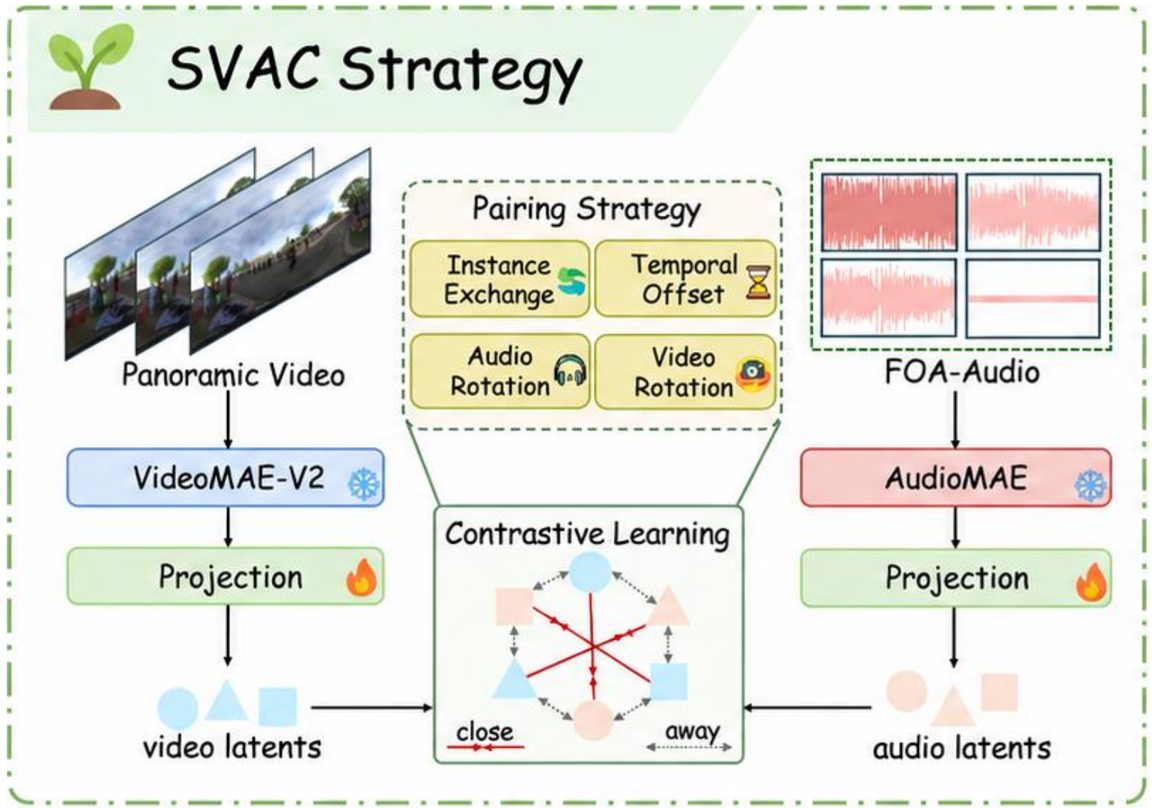
- **历史上下文**

  - 历史编码提供长程信息，前两个音频块提供局部边界条件，帮助声音与空间变化连续。

创新二：SVAC 视听空间对比学习

➢ **核心：利用语义、时间与空间错配，学习内容、同步关系与声源方位的对应。**

SVAC：用针对性的错配训练视听表示



- **联合对齐**

  - 通过对比学习，让视频与音频同时对齐声音内容、发生时间和声源方位。

- **错配构造**

  - 实例交换检验内容，时间偏移检验同步，独立旋转音频或视频检验方位对应。

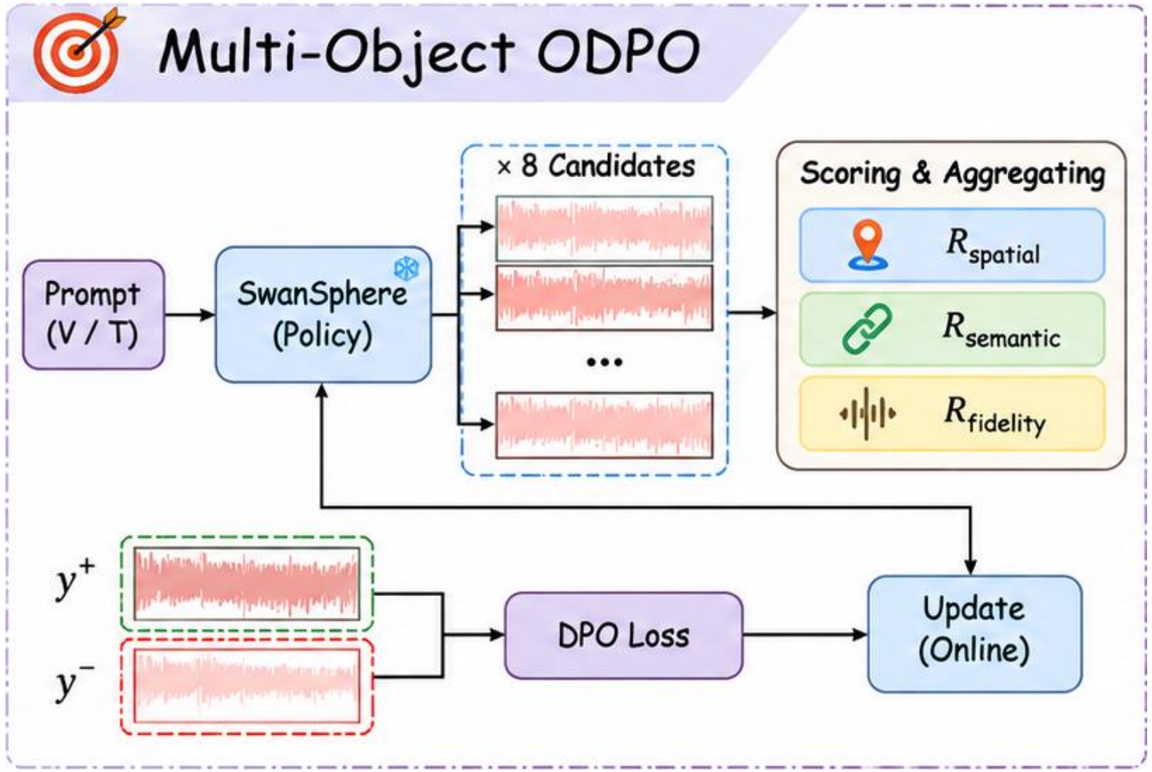
- **表示学习**

  - 基于 VideoMAE 与 AudioMAE 特征训练投影层，为后续生成提供更准确的空间条件,增强方向敏感性。

创新三：多目标在线偏好优化（ODPO）

➢ **核心：综合空间、语义与声学保真评分，通过在线偏好优化校准生成结果。**

多目标在线偏好优化流程



- **候选生成**

  - 对每个视频或文本条件生成 8 个候选，分别评估空间准确性、语义匹配与声学保真度。

- **偏好配对**

  - 三项分数归一化后按 0.4 / 0.4 / 0.2 加权，选择最高与最低分候选组成偏好对。

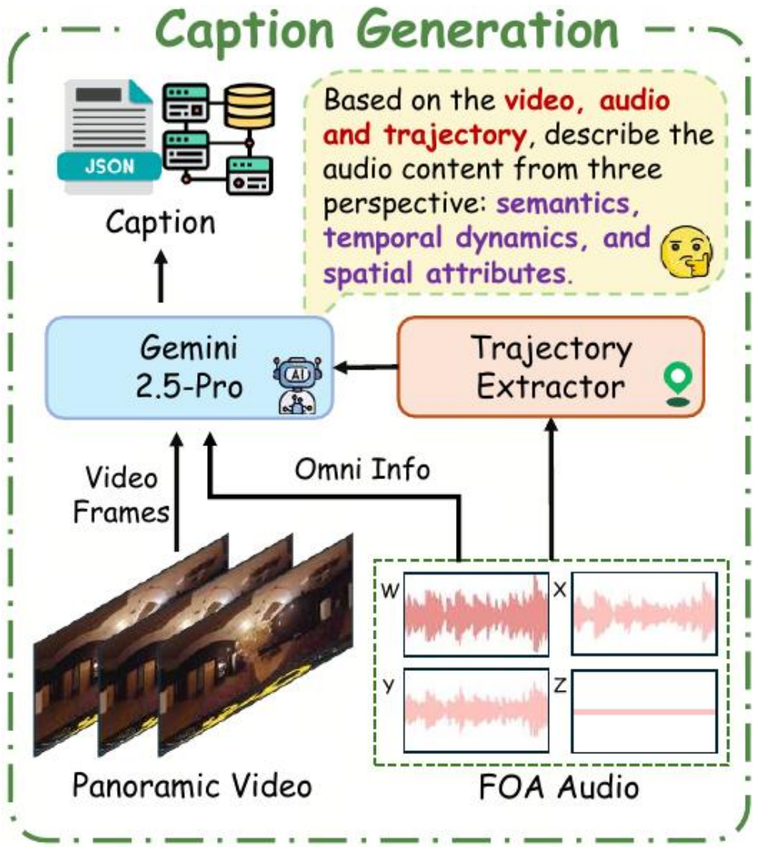
- **在线 DPO**

  - 以自动评分产生的偏好对更新模型，进一步改善内容、空间与声音质量的综合表现。

实验设置与评测数据

➢ **以配对视频—FOA 数据学习生成，并结合客观指标与主观听评验证。**

空间描述的自动标注流程



- **主要数据：视频与 FOA 配对**
  - 筛选后约 16.5 万对、458 小时，统一为 10 秒片段，5% 留作测试且视频 ID 不重叠。

- **补充数据：空间描述与预训练**
  - 约 3100 条空间描述中留出 300 条评测，另用约 100 万普通音频构造伪 FOA 辅助预训练。

- **评测质量、空间与响应效率**
  - 结合 FD、KL、角度误差、独立 wCS 与 MOS；首块延迟和整段生成耗时分别报告。

基线比较：视频与文本条件下的空间音频生成

➢ **视频与文本条件下生成质量更好，空间对齐与首块响应也得到改善。**

视频 → FOA 基线比较

Model	Params	Inf. Time ↓	FD↓	KL↓	$\Delta_{abs}\theta$ ↓	$\Delta_{abs}\phi$ ↓	$\Delta_{angular}$ ↓	MOS-SQ ↑	MOS-AF ↑
Ground Truth	-	-	-	-	-	-	-	4.60 ± 0.15	4.58 ± 0.21
MMAudio+AS	1.03B	2.76s	261.65	2.43	-	-	-	3.91 ± 0.18	3.60 ± 0.23
Diff-Foley+AS	0.94B	2.03s	304.03	3.12	-	-	-	3.68 ± 0.14	3.26 ± 0.17
ViSAGe	0.36B	20.19s	232.17	2.67	1.57	0.63	1.59	3.82 ± 0.20	3.78 ± 0.26
OmniAudio	1.22B	0.85s	157.67	1.93	1.25	0.47	1.27	4.12 ± 0.18	4.27 ± 0.17
Ours	1.09B	0.21s/9.13s	**120.28**	**1.36**	**1.14**	**0.4**	**1.03**	$\mathbf{4.32 \pm 0.15}$	$\mathbf{4.44 \pm 0.20}$

文本 → 空间音频基线比较

Model	Params	Inf. Time ↓	FD↓	KL↓	MOS-SQ ↑	MOS-AF ↑
Ground Truth	-	-	-	-	4.65 ± 0.17	4.76 ± 0.15
MMAudio+AS	1.03B	2.76s	313.26	2.77	3.75 ± 0.21	3.44 ± 0.24
AudioLDM-2+AS	0.71B	7.64s	294.17	2.45	3.86 ± 0.20	3.53 ± 0.17
Tango2+AS	0.86B	2.12s	235.71	2.42	3.95 ± 0.16	3.27 ± 0.21
OmniAudio(text)	1.22B	0.89s	174.13	1.83	4.11 ± 0.15	4.16 ± 0.18
Ours	1.09B	0.21s/9.13s	**142.80**	**1.43**	$\mathbf{4.31 \pm 0.18}$	$\mathbf{4.43 \pm 0.22}$

- **音质与方位同步改善**
  - FD、KL 与主观评分共同改善，角度误差也降低，说明声音更自然且更贴合画面中的方位。
- **内容与听感更贴合提示**
  - 客观分布与主观符合度同步改善，说明文本条件下也能生成更贴近目标场景的声音。
- **流式效率更高**
  - 首块等待不到次优的四分之一，分块流式输出让播放能够更早开始。

消融实验：关键模块与流式生成架构的有效性

➢ **SVAC 与 ODPO 改善音质和空间对齐，分块架构主要缩短首块等待。**

SVAC 对比学习消融

Model	FD ↓	KL ↓	$\Delta_{\text{abs}}\theta$ ↓	$\Delta_{\text{abs}}\phi$ ↓	Δ_{angular} ↓
Ours	**120.28**	**1.36**	**1.14**	**0.40**	**1.03**
sem-only	127.12	1.41	1.26	0.49	1.12
CLIP	140.28	1.44	1.31	0.55	1.34

- **SVAC时空错配增强方位感知**
  - 完整 SVAC 比仅语义对比的角度误差更低，说明内容匹配还需结合时间与方向监督。

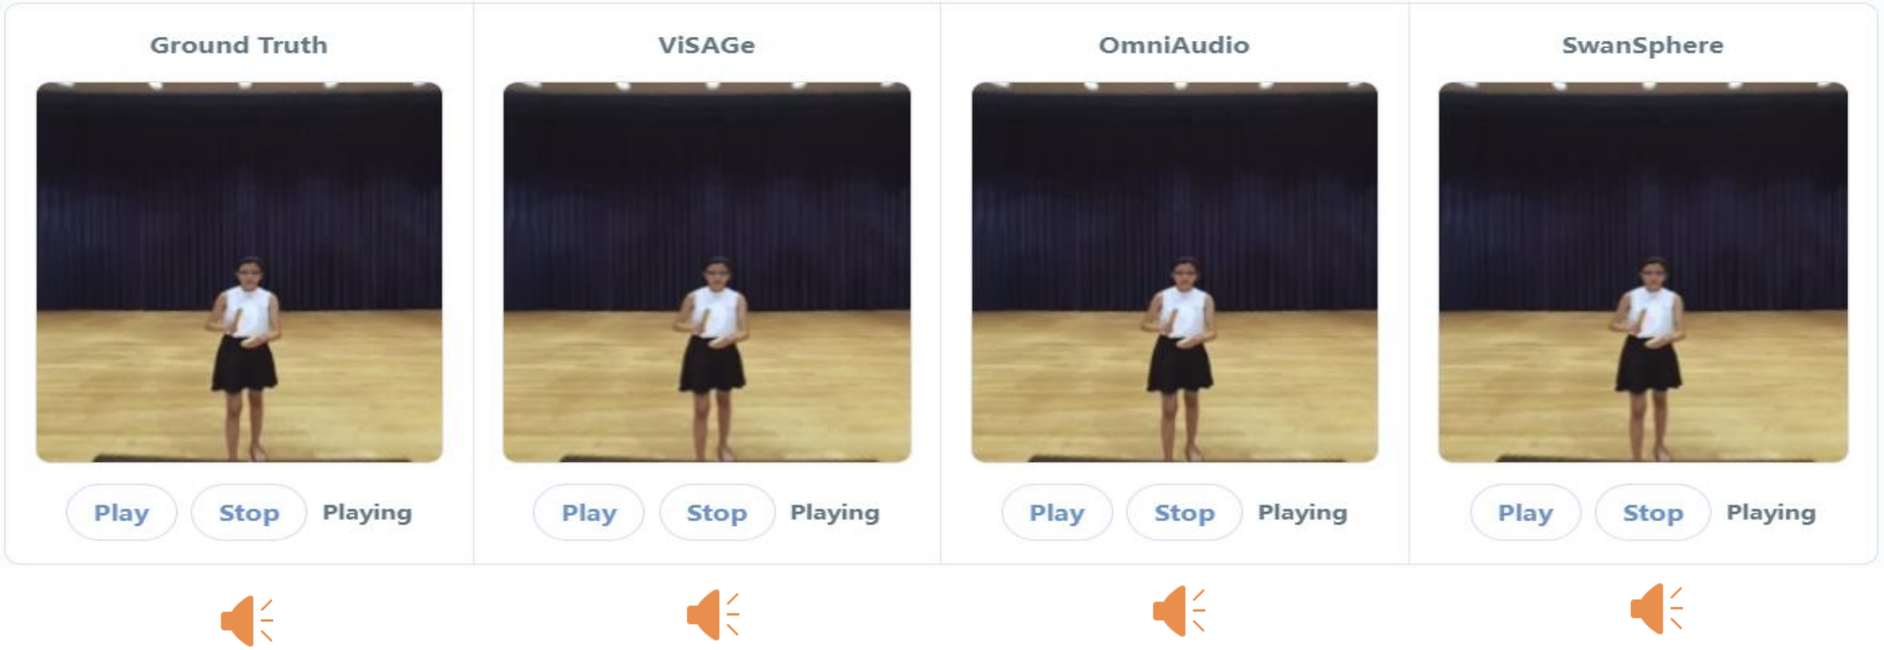
规模、ODPO 与生成范式

Model	Params	Inf. Time ↓	FD ↓	KL ↓	$\Delta_{abs}\theta$ ↓	$\Delta_{abs}\phi$ ↓	$\Delta_{angular}$ ↓
SwanSphere-L	1.09B	0.21s/9.13s	**120.28**	**1.36**	1.14	**0.40**	**1.03**
SwanSphere-M	0.62B	0.17s/7.60s	132.52	1.43	1.28	0.46	1.16
SwanSphere-S	0.43B	0.13s/6.10s	139.81	1.58	1.45	0.53	1.33
SwanSphere-L w/o ODPO	1.09B	0.21s/9.13s	133.91	1.44	1.21	0.43	1.22
DiT	1.11B	6.47s	123.08	1.36	**0.91**	0.46	1.14

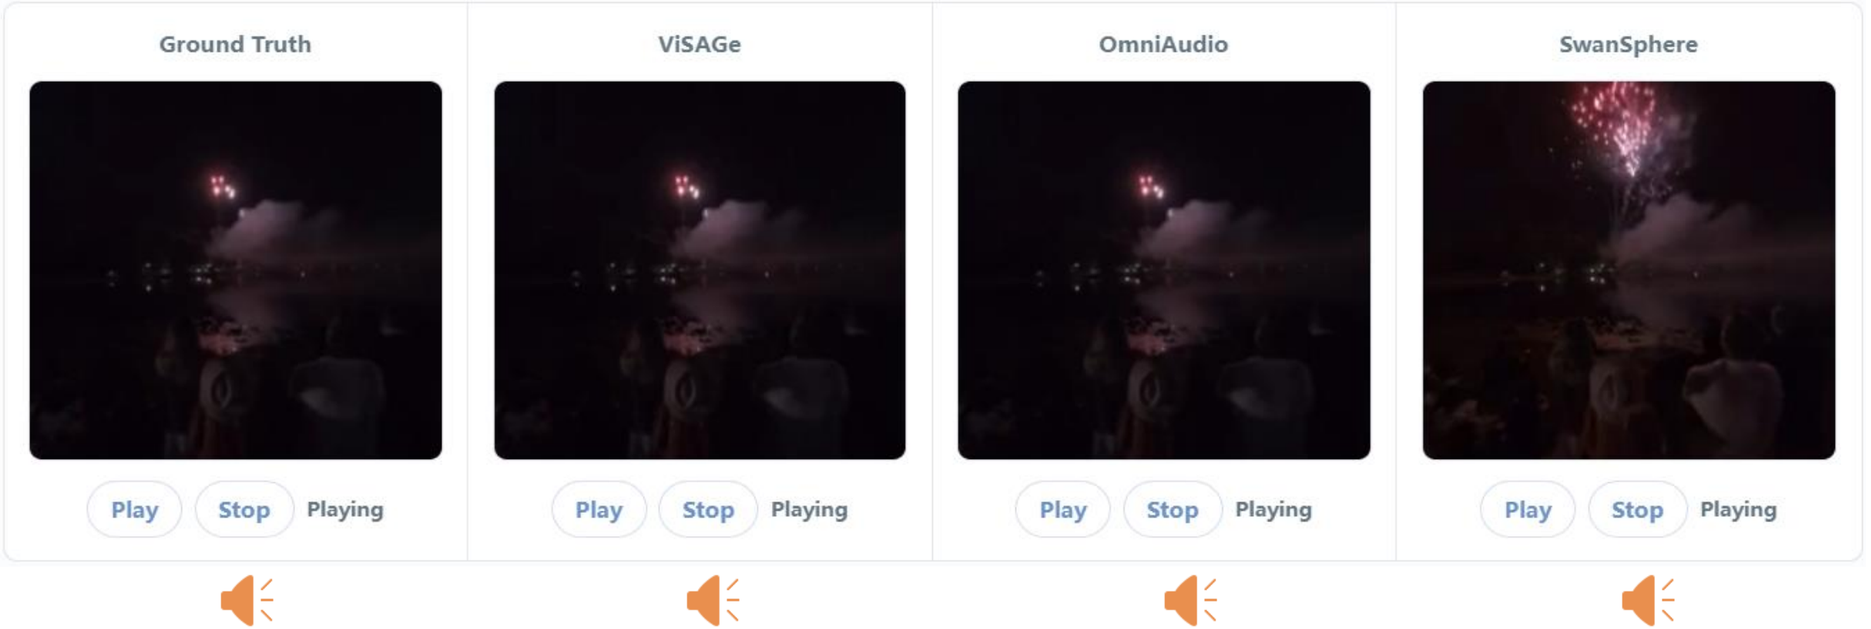
- **ODPO进一步校准音质与方位**
  - 移除 ODPO 后音质与角度误差均变差，表明多目标偏好监督能补充初始生成训练。

音频示例

示例1


Ground Truth
ViSAGe
OmniAudio
SwanSphere
Play
Stop
Playing
Play
Stop
Playing
Play
Stop
Playing
Play
Stop
Playing

示例2


Ground Truth
ViSAGe
OmniAudio
SwanSphere
Play
Stop
Playing
Play
Stop
Playing
Play
Stop
Playing
Play
Stop
Playing

挑战三：复杂3D空间音频的指令编辑与多任务统一难以实现

➢ **核心挑战：如何实现复杂3D空间音频的多任务、一体化指令编辑?**

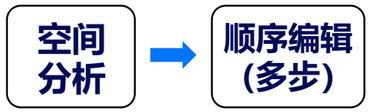
现有方法及不足

通用音频编辑



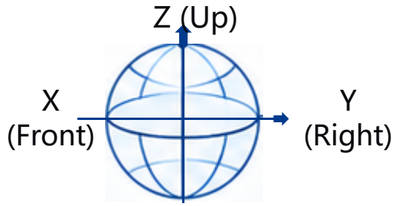
不足：采用离散表示，存在量化损失，影响声音质量。

分步式空间编辑



不足：需将复杂指令拆解为多步操作，误差易累积。

空间音频生成/编辑基线



不足：任务覆盖有限，难以统一处理事件、空间、动态与环境等多种编辑需求。

本项目思路（SWANWEAVE）

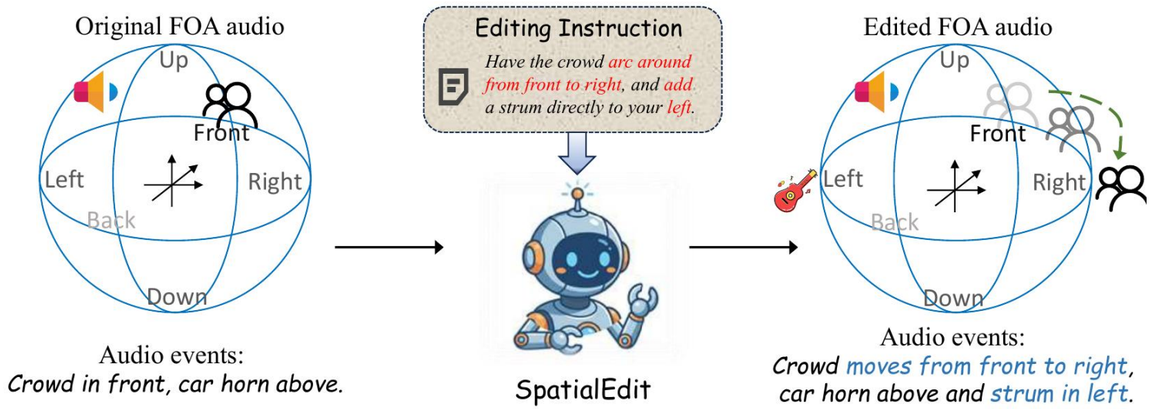
空间编辑混合专家(SE-MoE)

一阶段指令编辑

空间偏好优化(SPO)

SWANWEAVE：自然语言驱动的三维空间音频编辑

➢ **根据自然语言完成复合空间编辑，同时保留未编辑内容与场景。**



原始场景：人群在前方，汽车喇叭在上方。
编辑结果：人群移向右侧，并在左侧加入拨弦声。

- **任务：编辑已有的 FOA 场景**

  - 输入原始 FOA 音频与自然语言指令，输出编辑后的 FOA 音频。

- **编辑范围**

  - 支持声源增删、方位与距离变化、动态轨迹及房间混响调整。

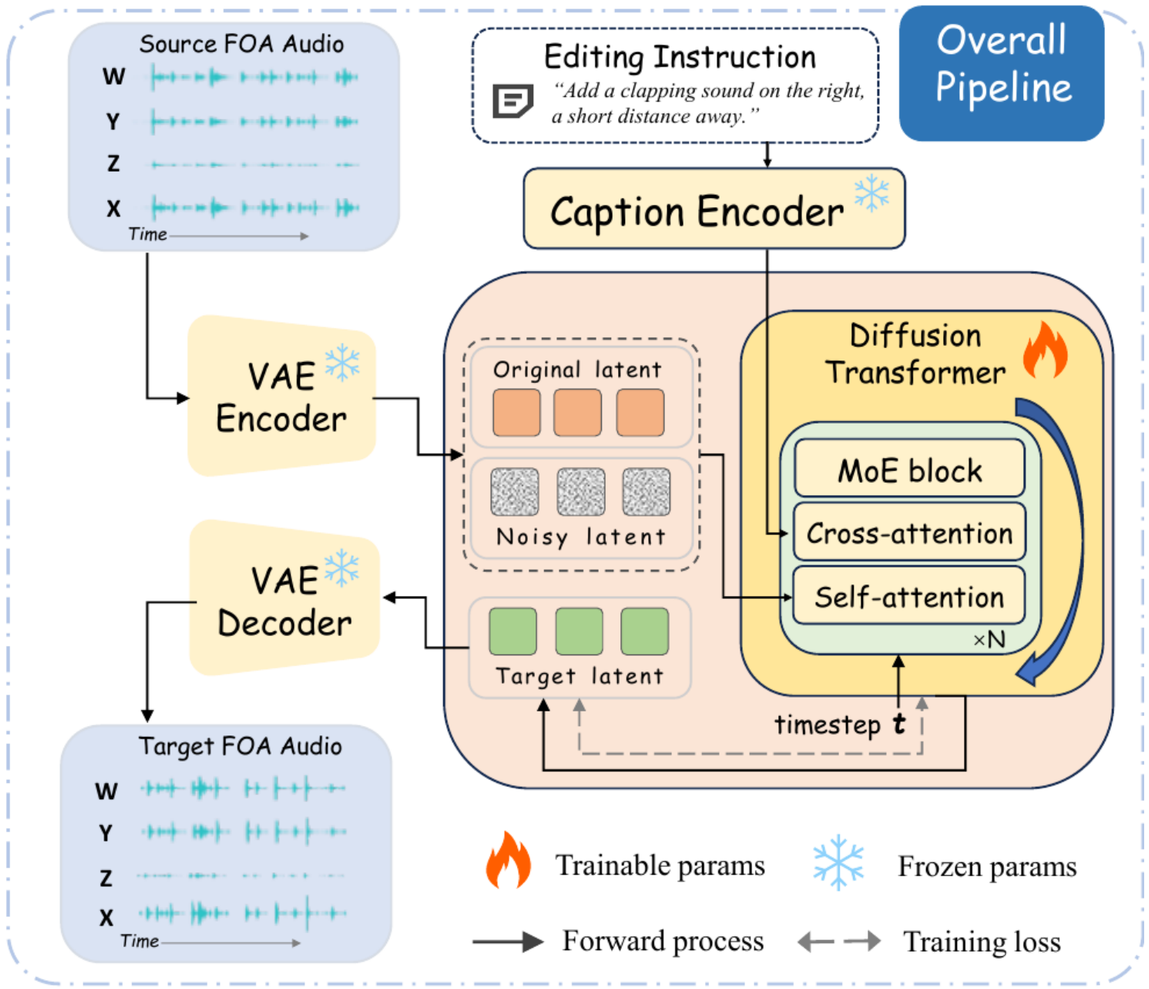
- **核心难点**

  - 复合指令需联合执行，同时尽量保持无关声源和原有场景的一致性。

https://github.com/MM-Speech/SwanWeave

创新一：一步式潜空间编辑与渐进训练

➢ **核心：在潜空间中联合执行整条指令，通过渐进训练学习复合编辑。**



- **潜表示**

  - 四通道波形先编码为连续潜变量，编辑后再解码为 FOA 音频。

- **一步式编辑**

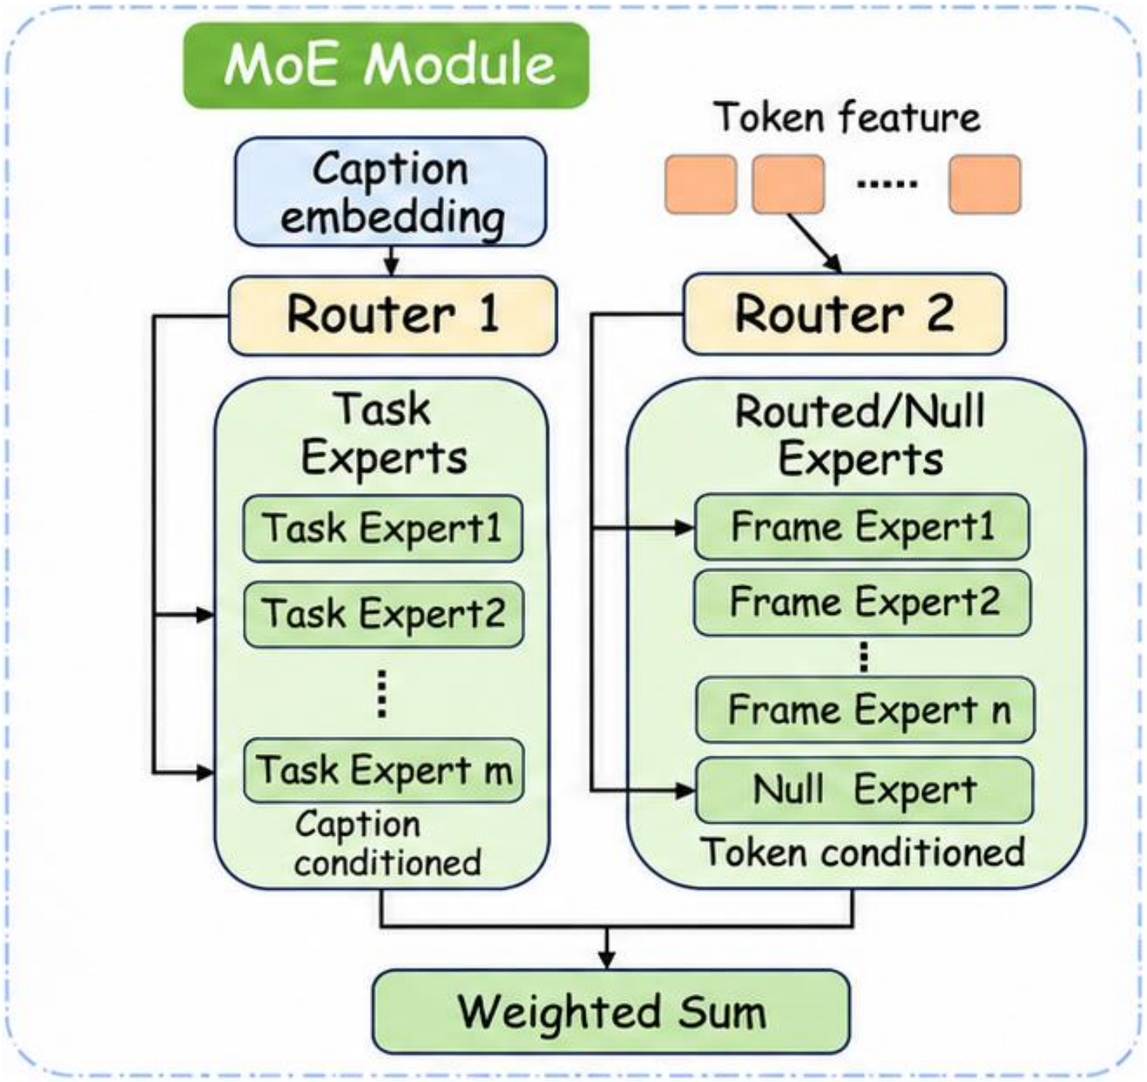
  - 源潜变量与加噪目标共同输入 DiT，指令通过交叉注意力提供条件。

- **渐进训练**

  - 先做文本到 FOA 预训练，再学习单操作，最后联合训练复合编辑。

创新二：SE-MoE 双层路由的空间编辑专家

➢ **核心：任务级与帧级路由分工处理复合指令，空专家帮助减少对无关区域的修改。**



- **任务级路由**

  - 将编辑指令编码为任务表示，选择合适的专家组合。

- **帧级路由**

  - 根据每个时间帧的 token 特征，选择激活的局部专家。

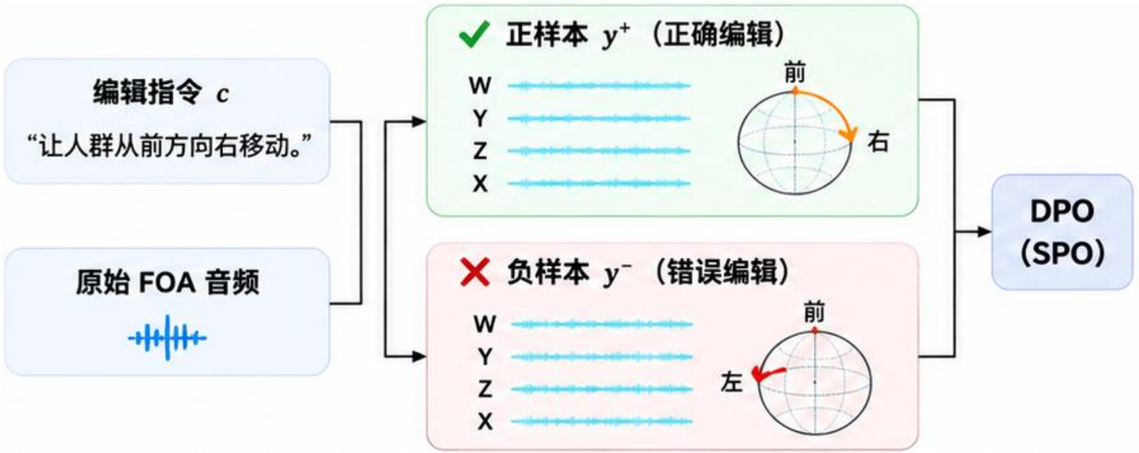
- **空专家机制**

  - 保持非编辑区域的稳定，减少无关变换。

创新三：空间偏好优化与分层条件引导

➢ **核心：用偏好监督减少编辑失败，并分别控制场景保持与指令执行。**

空间偏好优化（SPO）



分层条件引导（Staircase CFG）

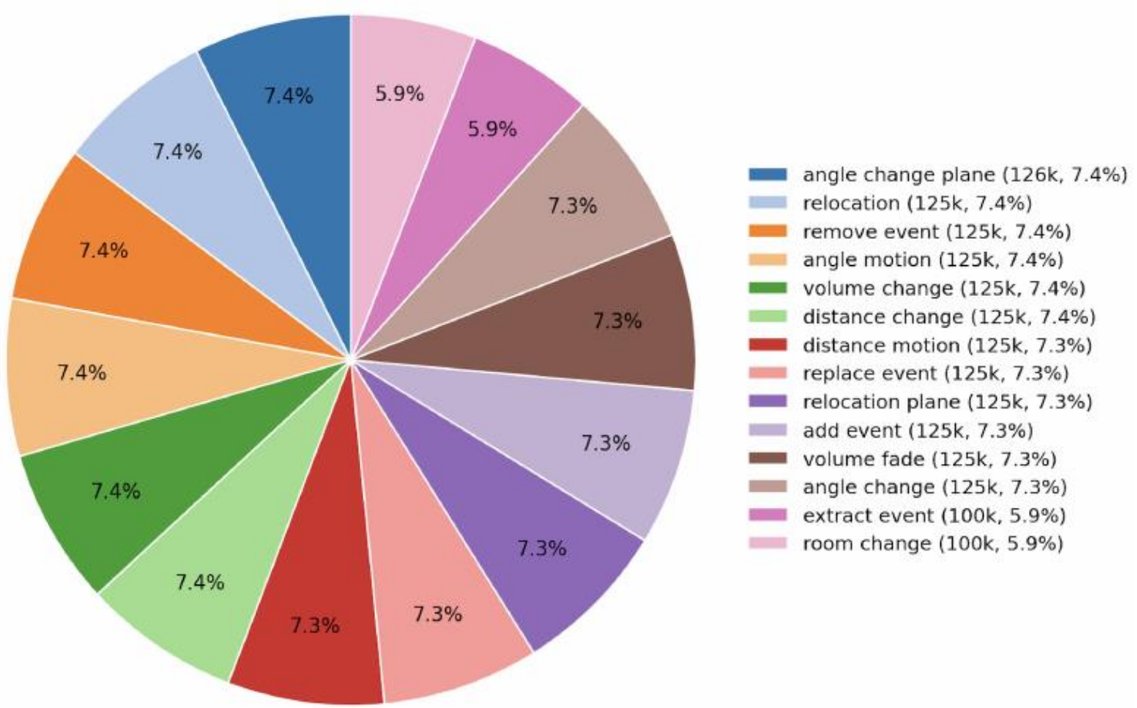
无条件预测 vø → **源音频条件 v源** → **完整条件 v完整**

- **偏好优化**
  - 以正确目标和典型失败目标构成偏好对，减少错声源、错方位和不执行编辑。
- **负例构造**
  - 错编辑与不操作按 2：1 构造负例，为具体编辑任务提供对比监督。
- **分层引导**
  - 先用源音频锚定原场景，再通过指令条件的增量施加编辑，平衡保持与修改。

数据与评测：多任务 FOA 编辑数据与评价体系

➢ **用配对 FOA 数据覆盖多类编辑，从音质、语义与空间三个方面评估。**

单操作编辑任务的数据分布



- **数据构建：可控仿真与配对监督**

  - 用开源语音与音效构建场景，每个源场景含 2—4 个事件，再以可控房间仿真渲染 FOA。

- **数据规模：单操作与复合编辑**

  - 多数单操作约 12.5 万条/类，复合编辑约 25 万条。训练与测试不共享原始音频。

- **评测：音质、指令与空间保持**

  - 用 FD/FAD、CLAP、GCC/CRW/FSAD 等指标结合人工偏好评价；空间指标在统一立体声域计算。

基线比较：编辑质量与空间一致性

➢ **相较基线，SWANWEAVE 编辑更快，质量与动态空间保持更好。**

整体编辑质量与空间一致性比较

Method	Speed	FD↓	FAD↓	KL↓	LSD↓	CLAP↑	GCC↓	CRW↓	FSAD↓	HP
ZETA	56.26s	14.84	4.03	4.43	3.29	0.17	51.85	22.12	0.78	17.88%-82.12%
AudioEditor	119.97s	8.66	3.19	2.46	2.89	0.19	28.19	44.50	0.55	25.67%-74.33%
SDEdit	32.28s	8.60	2.03	2.41	2.72	0.18	24.19	25.48	0.40	23.30%-76.70%
SmartDJ	4.23s	8.47	2.87	2.69	2.56	0.17	20.32	33.07	0.32	38.44%-61.56%
Ours	**1.17s**	**5.47**	**1.16**	**1.67**	**1.07**	**0.21**	**12.39**	**18.80**	**0.31**	-

动态空间编辑比较

Operation	Method	FD↓	FAD↓	KL↓	LSD↓	GCC↓	CRW↓	FSAD↓
Angle Motion	SmartDJ	6.70	2.40	1.92	2.36	23.25	50.16	0.29
	Ours	3.41	1.23	0.66	0.80	1.15	14.84	0.23
Dis Motion	SmartDJ	11.10	1.88	3.18	2.77	16.45	28.66	0.33
	Ours	5.54	0.93	1.25	0.86	1.74	11.32	0.22

- **总体比较上编辑效率与质量提升**
  - 本方法平均耗时最少，FD最优，说明音频分布更接近目标，执行效率高。
- **动态编辑方面，空间运动更接近目标**
  - 角度与距离运动的 GCC、CRW 均低于 SmartDJ，说明动态空间线索保留更好。
- **主观评价上整体偏好更高**
  - 与 SmartDJ 对比时，本方法获 61.56% 偏好，三名标注者综合评价音质与指令符合程度。

消融实验：关键模块与一步式编辑的作用

➢ **预训练、SE-MoE 与 SPO 均有贡献，一步式主要改善效率与空间保持。**

模型组件消融

Variation	FD↓	FAD↓	KL↓	LSD↓	CLAP↑	GCC↓	CRW↓	FSAD↓
w/o pretrain	8.49	3.15	2.78	2.33	0.16	21.24	25.09	0.39
w/o MoE	6.84	2.72	2.34	1.66	0.21	14.05	19.51	0.29
w/o task expert	6.21	2.14	1.98	1.24	0.18	13.76	17.91	0.38
w/o SPO	5.94	1.82	1.85	1.10	0.21	15.45	19.89	0.32

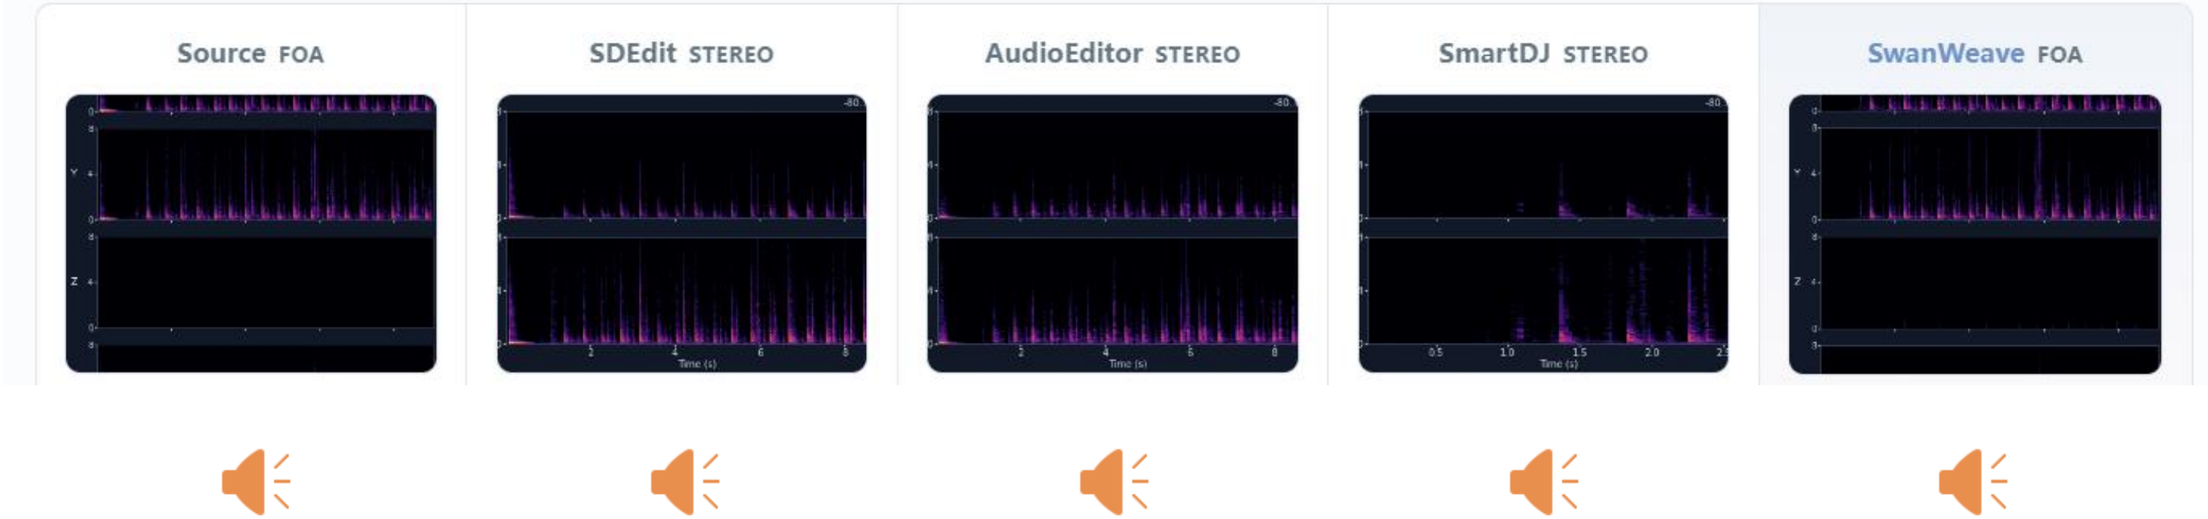
一步式与多阶段复合编辑

Method	Speed (s)↓	FD↓	FAD↓	KL↓	LSD↓	CLAP↑	GCC↓	CRW↓	FSAD↓
SmartDJ multi-stage	10.73	9.88	3.12	2.82	2.99	0.17	27.99	47.99	0.44
SmartDJ one-stage	4.23	8.47	2.87	2.69	2.56	0.17	20.32	33.07	0.32
Ours multi-stage	3.96	7.16	1.67	**1.36**	1.82	**0.23**	19.45	22.29	0.37
Ours one-stage	**1.17**	**5.47**	**1.16**	1.67	**1.07**	0.21	**12.39**	**18.80**	**0.31**

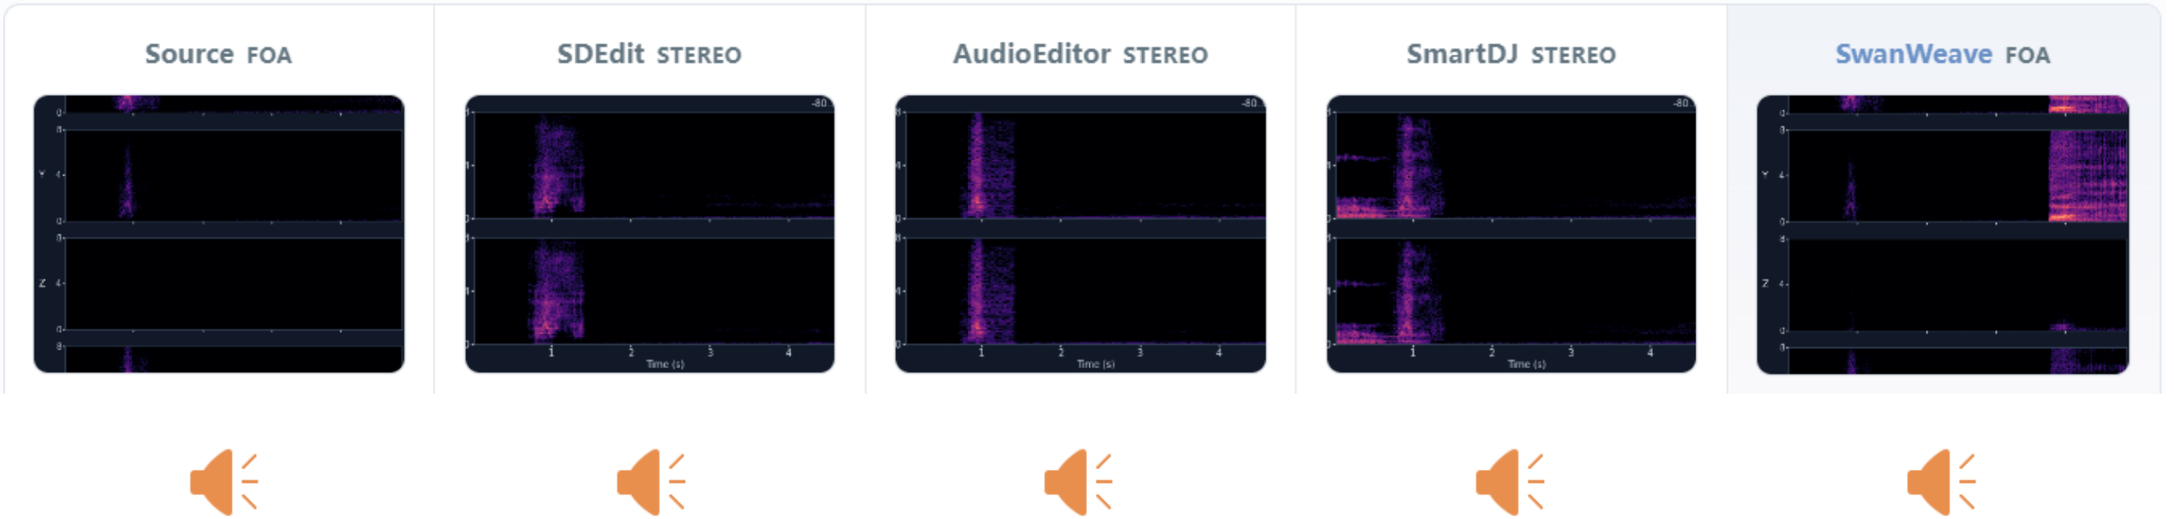
- **模块消融证明预训练与双层路由有效**
  - 去掉预训练或专家路由后，主要音质指标退化，说明场景基础与专家分工具有互补作用。
- **偏好后训练进一步减少编辑失败**
  - 移除 SPO 后，FD、FAD、KL、LSD 和主要空间指标变差，偏好监督可补充目标监督。
- **速度与空间一致性更好**
  - 相较多阶段，一步式耗时更少，重建与空间指标更好；KL、CLAP 仍存在取舍。

音频示例

去除低音鼓的声音。



在左侧附近添加一个打嗝和挤气声。



总结

➢ **研究目标:** 面向沉浸式交互，支撑高保真重建、视听同步生成与精确可控编辑。

➢ **技术突破:**

- **突破多声道空间线索保真与一致性保持技术**

  在不读取未来输入的条件下，保持跨声道线索并支持连续流式重建。

- **突破生成质量、空间对齐与低延迟协同优化技术**

  提升声音内容与方位的匹配程度，同时缩短首块音频的等待时间。

- **突破复杂空间属性精确调控与非目标内容保持技术**

  联合完成复合空间编辑，减少顺序编辑中的重建与空间误差累积。